### CE085 - Estatística Inferencial Função de Verossimilhança e suas derivadas

Prof. Wagner Hugo Bonat

Laboratório de Estatística e Geoinformação - LEG Curso de Bacharelado em Estatatística Universidade Federal do Paraná - UFPR

5 de setembro de 2018

# Conteúdo



#### Conteúdo

- ► Notação e definições.
- Verossimilhança e log-verossimilhança.
- ► Escore e informação de Fisher.
- Informação observada.
- Desigualdade de Cramér-Rao.



## Notação e Definições



### Notação

- ▶ O vetor  $(n \times 1)$  de variáveis aleatórias (va) é denotado por  $Y = (Y_1, ..., Y_n)^{\top}$ .
- ► O vetor  $(n \times 1)$  de realizações de uma va é denotado por  $\mathbf{y} = (y_1, \dots, y_n)^{\top}$ .
- ▶ Denote  $f(Y; \theta)$  a função de probabilidade (fp) caso discreto ou função de densidade probabilidade (fdp) do vetor aleatório Y.



#### Definições

- ▶ Definição 1 (Parâmetro ou vetor de parâmetros) Vetor de características numéricas de uma população. Denotaremos o vetor  $(p \times 1)$  de parâmetros por  $\theta$ . Em particular com p = 1(caso uniparamétrico) denotaremos  $\theta$ .
- Definição 2 (Espaço paramétrico) Espaço paramétrico é o conjunto de todas as possíveis combinações entre todos os valores para todos os diferentes parâmetros envolvidos em uma fp ou fdp. Notação Ω.
- Definição 3 (Suporte) Suporte é conjunto de valores realizáveis de uma va.
- Exemplos: Binomial, Poisson e normal.



### Verossimilhança - Caso uniparamétrico

▶ **Definição 4 (Verossimilhança)** Sejam dados y uma realização de um vetor aleatório Y com fp ou fdp  $f(Y, \theta)$ . A **função de verossimilhança**  $L(\theta): \Omega \to [0, \infty]$  para  $\theta$  é a função aleatória

$$L(\theta) \equiv f(\mathbf{Y}, \theta)$$

onde  $f(y_1, \dots, y_n | \theta)$  é a função de distribuição conjunta de **Y**.

1. Caso discreto não há ambiguidade então

$$L(\theta) \equiv P_{\theta}[Y = y].$$

2. Caso contínuo em geral as observações são medidas com algum grau de precisão em um intervalo  $(y_{il} \le y_i \le y_{iS})$ . Neste caso a verossimilhança é dada por

$$L(\theta) = P_{\theta}[y_{1l} \le y_1 \le y_{1S}, y_{2l} \le y_2 \le y_{2S}, \dots, y_{nl} \le y_n \le y_{nS}].$$



### Verossimilhança - Caso uniparamétrico

- Suponha que as observações são independentes e medidas com o mesmo grau de precisão.
- Assim, cada dado é medido em um intervalo  $(y_i \delta/2 \le Y_i \le y_i + \delta/2)$ .
- Com estas suposições a verossimilhança pode ser escrita como

$$L(\theta) = \prod_{i=1}^{n} P_{\theta}[y_i - \delta/2 \le Y_i \le y_i + \delta/2]$$
$$= \prod_{i=1}^{n} \int_{y_i - \delta/2}^{y_i + \delta/2} f(y_i, \theta) d(y_i).$$



### Verossimilhança - Caso uniparamétrico

► Se o grau de precisão é alto ( $\delta$  é pequeno) em relação a variabilidade dos dados, a expressão se reduz a

$$L(\theta) \approx \left(\prod_{i=1}^n f(y_i, \theta)\right) \delta^n.$$

Finalmente, se  $\delta$  não depende de  $\theta$ , temos

$$L(\theta) \approx \prod_{i=1}^{n} f(y_i, \theta),$$

▶ Para enfatizar que a verossimilhança é avaliada nas observações usamos a notação  $L(\theta|\mathbf{y})$ .



(2)

#### Verossimilhança - Condições de regularidade

- 1. O parâmetro  $\theta$  é **identificável**. Isso significa que se  $f(\theta_1|\mathbf{y}) = f(\theta_2|\mathbf{y})$  para quase todos  $\mathbf{y} \in \Re$ , então  $\theta_1 = \theta_2$ .
- 2. O suporte de  $f(\theta|\mathbf{y})$  é o mesmo para todo  $\theta \in \Re$ .
- 3. O verdadeiro valor do parâmetro  $\theta_0$  pertence ao interior de  $\Omega$ .
- 4.  $f(\theta|\mathbf{y})$  é duas vezes continuamente diferenciável com relação  $\theta$  para quase todo  $\mathbf{y} \in \Re$ .
- 5.  $\frac{\partial}{\partial \theta}$  e  $\int$  (caso contínuo), ou  $\frac{\partial}{\partial \theta}$  e  $\sum$  (caso discreto) podem ser intercambiada.
  - \*\* Para quase todo significa que a condição não é verdadeira para um conjunto de **y** com probabilidade zero de ocorrência.

#### Log-Verossimilhança

▶ A função de log-verossimilhança é a função estocástica  $I(\theta): \Omega \to \Re$  definida por

$$I(\theta|\mathbf{y}) = \log(L(\theta|\mathbf{y}))$$
.

► No caso iid, tem-se

$$I(\theta|\mathbf{y}) = \sum_{i=1}^{n} \log (L(\theta|\mathbf{y}_i)).$$

▶  $I(\theta|\mathbf{y}) = -\infty$  quando  $L(\theta) = 0$ , mas isso ocorre quando  $f(y_1, \dots, y_n|\theta) = 0$  que tem probabilidade de ocorrência igual a zero.

#### Exemplo

 Sejam Y<sub>1</sub>,..., Y<sub>n</sub> iid ensaios Bernoulli com probabilidade de sucesso μ. Escreva a função de verossimilhança, log-verossimilhança e verifique se as condições de regularidade estão satisfeitas.



### Transformação de parâmetros

▶ Suponha que o interesse seja trabalhar com  $\psi$  definido por  $\theta = g(\psi)$  ao invés de  $\theta$ . Assuma que g é 1-1. Então, a log-verossimilhança para  $\psi$  é dada por

$$\tilde{I}(\psi) = \sum_{i=1}^{n} \log f(y_i, g(\psi)),$$

apenas inserimos  $g(\psi)$  em  $I(\cdot)$  para obter a nova log-verossimilhança.



### Exemplo: Transformação de parâmetros

▶ Suponha que desejamos escrever a log-verossimilhança para  $\psi = \log \frac{\mu}{1-\mu}$ . Note que  $\mu = \frac{\exp^{\psi}}{1+\exp^{\psi}}$ .



### Exemplo: Transformação de parâmetros

▶ Suponha que desejamos escrever a log-verossimilhança para  $\psi = \log \frac{\mu}{1-\mu}$ . Note que  $\mu = \frac{\exp^{\psi}}{1+\exp^{\psi}}$ .

$$\tilde{I}(\psi) = \sum_{i=1}^{n} y_i \psi - n \log(1 + \exp^{\psi}).$$



#### Transformação nos dados

► Considere uma transformação 1 - 1  $Y_i = h(X_i)$  que será usada na log-verossimilhança ao invés de  $X_i$ . Considere o caso contínuo e que h é diferenciável. Então  $Y_i$  tem densidade dada por  $f(h^{-1}(y), \theta) \frac{dx}{dy}(y)$ , assim a nova verossimilhança será

$$\begin{split} \widetilde{I}(\theta) &= \widetilde{I}(\theta|Y_1, \dots, Y_n) \\ &= \sum_{i=1}^n \log \left( f(h^{-1}(y_i), \theta) \frac{dx_i}{dy_i} Y_i \right) \\ &= \sum_{i=1}^n \log \left( f(h^{-1}(y_i), \theta) \right) + \log \left( \frac{dx_i}{dy_i} Y_i \right) \\ &= I(\theta|X_1, \dots, X_n) + const. \end{split}$$

► Em geral estamos interessados nas derivadas de  $I(\cdot)$  que não dependem da constante.

Para fins de estimação a constante pode ser desconsiderada

Qual seria a melhor transformação para os dados?

Wagner Hugo Bonat CE085 - Estatística Inferencial 15/22

### Desigualdade de Jensen e Máxima Verossimilhança

- Seja g uma função estritamente convexa e Y uma v.a com  $E(|Y|) < \infty$  tal que a distribuição de Y é não degenerada. Então g(E(Y)) < E(g(Y)). Por outro lado, se g é estritamente concava, então g(E(Y)) > E(g(Y)).
- Demonstração: Exercício.
- ▶ Teorema 1: Seja  $\theta_0$  o verdadeiro valor do parâmetro. Então,

$$P_{\theta_0}(L(\theta_0|\mathbf{y}) > L(\theta|\mathbf{y})) \to 1$$
, quando  $n \to \infty$ .

- Demonstração.
- ▶ Interpretação:  $L(\theta_0) > L(\theta)$  com alta probabilidade para n grande. Assim,  $L(\theta)$  vai tender a ter o seu máximo próximo a  $\theta_0$ , o verdadeiro valor de  $\theta$ .
- Motiva a ideia de estimação por máxima verossimilhanca.

#### Definições

- ▶ Uma **estatística** é uma variável aleatória T = t(Y), onde a função  $t(\cdot)$  não depende de  $\theta$ .
- Uma estatística T é um estimador para  $\theta$  se o valor realizado t = t(y) é usado como uma estimativa para o valor de  $\theta$ .
- ➤ A distribuição de probabilidade de T é chamada de distribuição amostral do estimador t(Y).
- ► O viés de um estimador *T* é a quantidade

$$B(T) = E(T - \theta).$$

O estimador T é dito não viciado para  $\theta$  se B(T) = 0, tal que  $E(T) = \theta$ .

▶ O estimador T é assintóticamente não viciado para  $\theta$  se  $E(T) \to \theta$  quando  $n \to \infty$ .



### Definições

- ▶ A eficiência relativa entre dois estimadores  $T_1$  e  $T_2$  é a razão  $er = \frac{V(T_1)}{V(T_2)}$  em que  $V(\cdot)$  denota a variância.
- ▶ O erro quadrático médio de um estimador *T* é a quantidade

$$EQM(T) = E((T - \theta)^2) = V(T) + B(T)^2.$$

- ▶ Um estimador T é **médio quadrático consistente** para  $\theta$  se o  $EQM(T) \rightarrow 0$  quando  $n \rightarrow \infty$ .
- ▶ O estimador T é **consistente em probabilidade** se  $\forall \epsilon > 0$ ,  $P(|T \theta| > \epsilon) \rightarrow 0$ , quando  $n \rightarrow \infty$ .



#### Função escore e Informação de Fisher

Função escore para  $\theta$  (efficient score)

$$U(\theta|\mathbf{Y}) = U(\theta|\mathbf{Y}_1, \dots, \mathbf{Y}_n)$$

$$= \sum_{i=1}^n \frac{\partial}{\partial \theta} I(\theta, \mathbf{Y}_i).$$

$$= \sum_{i=1}^n \frac{\partial}{\partial \theta} \log f(\theta, \mathbf{Y}_i).$$

► Informação de Fisher ou Informação esperada

$$I_E(\theta) = Var(U(\theta|\mathbf{Y})).$$

► Informação de Fisher também é chamada de intrinsic accuracy.



#### Igualdades de Bartlett

- ► Sob condições de regularidade (slide 10), tem-se
  - 1. Primeira igualdade  $E(U(\theta|\mathbf{Y})) = 0$ .
  - 2. Segunda igualdade  $I_E(\theta) = -E(I''(\theta|\mathbf{Y})) = -E(U'(\theta|\mathbf{Y}))$ .
- ▶ Implicação:  $Var(U(\theta|Y)) = E(U(\theta|Y)^2)$ .
- ► Exemplo: Bernoulli e Poisson.
- ► Demonstração.



#### Informação observada

Informação observada para  $\theta$ 

$$I_{O}(\theta) = -I''(\theta|\mathbf{Y}).$$

► Note que

$$I_{\mathsf{E}}(\theta) = \mathsf{E}(I_{\mathsf{O}}(\theta)).$$

► Além disso, pela lei dos grandes números

$$I_{O}(\theta) \stackrel{P}{\rightarrow} I_{E}(\theta)$$
 quando  $n \rightarrow \infty$ .



#### Desigualdade de Cramér-Rao

► Teorema: If  $\tilde{\theta}(Y_1, ..., Y_n)$  é um estimador não viciado para  $\theta$ , então

$$Var(\tilde{\theta}) \geq I_E(\theta)^{-1}$$
.

- A quantidade  $I_E(\theta)^{-1}$  é chamado de limite inferior de Cramér-Rao.
- ► Um estimador não viciado é chamado eficiente se  $V(\tilde{\theta}) = I_E(\theta)^{-1}$ .
- ► Exemplos: Geométrica e Poisson.
- ▶ Demonstração.
- Exemplo patológico: Distribuição uniforme.

