CE085 - Estatística Inferencial Vetor de parâmetros

Prof. Wagner Hugo Bonat

Laboratório de Estatística e Geoinformação - LEG Curso de Bacharelado em Estatatística Universidade Federal do Paraná - UFPR

5 de outubro de 2018

Conteúdo



Conteúdo

- ▶ Vetor escore e matrix de informação de Fisher.
- ▶ Desigualdade de Cramér-Rao (generalizada).
- Propriedades do MLE.
- Ortogonalidade.
- Modelos exponenciais de dispersão.
- Regressão Linear.
- Exemplos.



Configuração geral

- ▶ Sejam $Y_1, ..., Y_n$ v.a com fdp ou fp $f(y, \theta)$.
- ► Vetor de parâmetros: $\theta = (\theta_1, ..., \theta_p)^\top \in \Omega$, onde Ω é uma região no \Re^p .
- ▶ Exemplo 1: $Y_i \sim G(\mu, \sigma^2)$

$$f(y, \theta) = \frac{1}{1\sqrt{2\pi}\sigma} \exp\left\{-\frac{1}{2\sigma^2}(y - \mu)^2\right\}, \quad y \in \Re \quad \mathbf{e} \quad \theta = (\mu, \sigma)^{\top}$$

▶ Exemplo 2: $Y_i \sim Ga(\theta, \lambda)$

$$f(y,\theta) = \frac{\theta^{\lambda}}{\Gamma(\lambda)} y^{\lambda-1} \exp^{-\theta y}, \quad y > 0 \quad e \quad \theta = (\theta,\lambda)^{\top} \in \Re^2_+.$$



Verossimilhança e log-verossimilhança

► Função de verossimilhança $L:\Omega\to [0,\infty]$ é uma função aleatória de um **vetor** de argumentos definida por

$$L(\theta|\mathbf{y}) = \prod_{i=1}^{n} f(y_i, \theta),$$
 para $\theta \in \Omega$.

Função de log-verossimilhança $I:\Omega\to\Re$ é uma função aleatória de um **vetor** de argumentos definida por

$$I(\theta|\mathbf{y}) = \sum_{i=1}^{n} \log f(\mathbf{y}_{i}, \theta).$$

Equivalentemente,

$$I(\theta|\mathbf{y}) = \log L(\theta|\mathbf{y}).$$



Vetor escore

▶ O vetor escore $U(\theta|\mathbf{y}): \Omega \to \Re^p$ é um vetor aleatório $p \times 1$ definido por

$$\mathbf{U}(\boldsymbol{\theta}|\mathbf{y}) = \frac{\partial l(\boldsymbol{\theta}|\mathbf{y})}{\partial \boldsymbol{\theta}} = \begin{pmatrix} \frac{\partial l(\boldsymbol{\theta}|\mathbf{y})}{\partial \theta_1} \\ \vdots \\ \frac{\partial l(\boldsymbol{\theta}|\mathbf{y})}{\partial \theta_p} \end{pmatrix}.$$

Notação popular em termos de gradiente

$$U(\theta|\mathbf{y}) = \nabla_{\theta} I(\theta|\mathbf{y}).$$

▶ Notação *j*-ésimo componente de $U(\theta|y)$ por $U_i(\theta|y)$.



Esperança do vetor escore

O vetor escore satisfaz as igualdades de Bartlett, ou seja,

$$E(U(\theta|Y)) = 0$$
,

isso significa que

$$E(U_j(\theta|Y)) = 0$$
, para $j = 1, ..., p$.



Matriz de informação esperada

 \triangleright A matriz $p \times p$ definida por

$$\begin{aligned} \mathsf{I}(\theta) &=& \mathsf{Var}(\mathsf{U}(\theta|\mathsf{Y})) \\ &=& \mathsf{E}(\mathsf{U}(\theta|\mathsf{Y})\mathsf{U}^\top(\theta|\mathsf{Y})). \end{aligned}$$

é chamada de matriz de informação esperada.

► As entradas j e k são expressadas por

$$I_{jk}(\theta) = Cov(U_j(\theta|Y), U_k(\theta|Y))$$

$$= E(U_j(\theta|Y), U_k(\theta|Y)).$$
(1)





Reparametrização

Seja $\theta = g(\psi), g: 1-1$ diferenciável o vetor escore fica dada por

$$\tilde{\mathbf{U}}(\boldsymbol{\theta}|\mathbf{Y}) = \frac{\partial \boldsymbol{\theta}^{\top}}{\partial \boldsymbol{\psi}} \mathbf{U}(\boldsymbol{\theta}|\mathbf{Y}).$$

Matriz de informação esperada

$$\tilde{\mathsf{I}}(\psi) = \frac{\partial \boldsymbol{\theta}^\top}{\partial \psi} \mathsf{I}(\boldsymbol{\theta}) \frac{\partial \boldsymbol{\theta}}{\partial \psi^\top}$$



Matriz de informação observada

A matriz $p \times p$ definida por

$$J(\boldsymbol{\theta}) = -\frac{\partial^2 I(\boldsymbol{\theta}|\mathbf{y})}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}^\top}.$$

► As entradas j e k da matriz de informação observada é dada por

$$J_{jk}(\boldsymbol{\theta}) = -\frac{\partial^2 I(\boldsymbol{\theta}|\mathbf{y})}{\partial \theta_i \partial \theta_k}.$$

Segunda igualdade de Bartlett

$$I(\theta) = E(J(\theta)).$$



Desigualdade de Cramér-Rao generalizada

▶ Define $I^{jk}(\theta) = \{I^{-1}(\theta)\}_{jk}$. Se $\tilde{\theta} = \tilde{\theta}(Y_1, \dots, Y_n)$ é um estimador não-viciado para θ_1 , ou seja,

$$E(\tilde{\theta}) = \theta_1,$$

então

$$\operatorname{Var}(\tilde{\theta}) \geq I^{11}(\theta).$$

 Demonstração análoga ao caso univariado usando a desigualdade de Cauchy-Schwarz generalizada.



Normalidade assintótica do vetor escore

Vetor escore

$$U(\theta|Y) = \sum_{i=1}^{n} \frac{\partial}{\partial \theta} \log f(\theta|y_i),$$

é a soma de v.a. iid com média zero, ou seja,

$$\mathbb{E}\left\{\sum_{i=1}^n \frac{\partial}{\partial \theta} \log f(\theta|y_i)\right\} = \mathbf{0}$$

e variância igual a matriz de informação de Fisher.

$$\operatorname{Var}\left\{\sum_{i=1}^{n}\frac{\partial}{\partial\theta}\log f(\theta|y_{i})\right\}=\mathrm{I}(\theta).$$



Normalidade assintótica do vetor escore

 Usando a versão multivariada do Teorema Central do Limite, temos

$$I^{-\frac{1}{2}}(\theta)U(\theta|Y) \stackrel{D}{\rightarrow} N_p(\mathbf{0},\mathbf{I}),$$

onde I denota a $p \times p$ matriz identidade.

► De forma equivalente,

$$\mathbf{U}(\theta|\mathbf{Y}) \stackrel{D}{\rightarrow} N_p(\mathbf{0}, \mathbf{I}(\theta)).$$

Note que pela lei dos grandes números

$$J(\boldsymbol{\theta}) \stackrel{P}{\rightarrow} I(\boldsymbol{\theta}),$$

assim podemos usar $J(\theta)$ quando calcular $I(\theta)$ for dificil/impossível.



Estimador de máxima verossimilhança

▶ O EMV $\hat{\theta} \in \Omega$ é definido por $L(\hat{\theta}) \ge L(\theta)$ para qualquer $\theta \in \Omega$. Em geral, $\hat{\theta}$ satisfaz a equação de verossimilhança

$$U(\theta|Y)=0.$$

▶ Um sistema com p equações e p incógnitas

$$\begin{pmatrix} U_1(\theta|\mathbf{y}) = 0 \\ \vdots \\ U_p(\theta|\mathbf{y}) = 0 \end{pmatrix}$$



Propriedades do Estimador de máxima verossimilhança

- ▶ Sendo θ_0 o verdadeiro valor do vetor de parâmetros θ . Então
 - 1. Consistência: $\hat{\theta} \stackrel{P}{\rightarrow} \theta_0$, ou seja,

$$P\left(\left\|\hat{\boldsymbol{\theta}}-\boldsymbol{\theta}_0\right\|>\epsilon\right) o 0, \quad \text{quando} \quad n o \infty.$$

2. Normalidade assintótica:

$$\hat{\boldsymbol{\theta}} \stackrel{D}{\to} N_p(\boldsymbol{\theta}, \mathbf{I}^{-1}(\boldsymbol{\theta})), \text{ quando } n \to \infty.$$

► Exemplos: Distribuição Normal, distribuição Gamma.



Parâmetros ortogonais

▶ Considere um modelo estatístico parametrizado por $\theta = (\theta_1, \theta_2)^{\top}$. No caso da matriz de informação de Fisher ser diagonal

$$I(\theta) = \begin{pmatrix} I_{11}(\theta) & 0 \\ 0 & I_{22}(\theta) \end{pmatrix},$$

os parâmetros θ_1 e θ_2 são ditos **ortogonais**.

O inverso da informação de Fisher é também diagonal

$$\mathrm{I}^{-1}(\theta) = \begin{pmatrix} 1/\mathrm{I}_{11}(\theta) & 0 \\ 0 & 1/\mathrm{I}_{22}(\theta) \end{pmatrix}.$$

► Assim, $\hat{\theta}_1$ e $\hat{\theta}_2$ são assintóticamente independentes com distribuição

$$\hat{\theta}_j \stackrel{a}{\sim} \mathsf{N}(\theta_j, 1/\mathrm{I}_{jj}(\boldsymbol{\theta})).$$



Parâmetros ortogonais: Generalização

▶ Considere um modelo estatístico parametrizado por $\theta = (\theta_1, \theta_2)^{\top}$. No caso da matriz de informação de Fisher ser bloco diagonal

$$I(\theta) = \begin{pmatrix} I_1(\theta) & 0 \\ 0 & I_2(\theta) \end{pmatrix},$$

os vetores de parâmetros θ_1 e θ_2 são ditos **ortogonais**.

- A distribuição assintótica de θ_1 é a mesma se θ_2 é considerado conhecido ou desconhecido.
- Definição similar pode ser feita usando a matriz de informação observada.
- Exemplos: Modelos exponenciais de dispersão, regressão linear.

