# CE085 - Estatística Inferencial Suficiência

Prof. Wagner Hugo Bonat

Laboratório de Estatística e Geoinformação - LEG Curso de Bacharelado em Estatatística Universidade Federal do Paraná - UFPR

8 de outubro de 2018

# Conteúdo



#### Conteúdo

- ► Definição e motivação.
- Critério da fatorização de Fisher-Neyman.
- ► Teorema de Rao-Blackwell.
- ► Teorema de Lehmann-Scheffé.
- Exemplos.



#### Exemplo de motivação

▶ Seja  $Y_i \sim N(\mu, \sigma^2)$  iid com log-verossimilhança

$$\begin{split} I(\mu, \sigma^2) &= -\frac{n}{2} \log(2\pi) - n \log(\sigma) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2 \\ &= -\frac{n}{2} \log(2\pi) - n \log(\sigma) - \frac{1}{2\sigma^2} \left( \sum_{i=1}^n y_i^2 + n\mu^2 - 2\mu \sum_{i=1}^n y_i \right). \end{split}$$

► Note que a log-verossimilhança é determinada por

$$S_Y = \sum_{i=1}^n y_i$$
 e  $S_{YY} = \sum_{i=1}^n y_i^2$ ,

a estatística  $(S_Y, S_{YY})^{\top}$  é chamada **suficiente** para  $(\mu, \sigma^2)$ .



#### Exemplo de motivação

 Podemos escrever a log-verossimilhança apenas como função das estatísticas suficientes

$$I(\mu,\sigma^2) = -\frac{n}{2}\log(2\pi) - n\log(\sigma) - \frac{1}{2\sigma^2}(S_{YY} + n\mu^2 - 2\mu S_Y).$$

- Dimensão da estatística suficiente é igual ao número de parâmetros (neste caso).
- ightharpoonup Suponha que  $\sigma^2=1$  neste caso a log-verossimilhança é

$$I(\mu) = -\frac{n}{2}\log(2\pi) - \frac{1}{2}S_{YY} - \frac{1}{2}n\mu^2 + \mu S_Y.$$

A constante  $-\frac{n}{2}\log(2\pi) - \frac{1}{2}S_{YY}$  não influência o corpo da log-verossimilhança.



#### Definição: Sufiência

▶ Seja  $Y_1, ..., Y_n$  iid com fdp ou fp  $f(y; \theta)$  para  $\theta \in \Omega$ . Seja

$$X_1 = u_1(Y_1, \dots, Y_n)$$

uma estatística com fdp ou fp  $f_{X_1}(y; \theta)$ .

▶ **Definição**: A estatística  $X_1$  é chamada **suficiente** para o parâmetro  $\theta$  se e somente se

$$\frac{f(y_1;\theta)\dots f(y_n;\theta)}{f_{X_1}(u_1(y_1,\dots,y_n))}=H(y_1,\dots,y_n),$$

onde  $H(y_1, ..., y_n)$  é uma função que não depende de  $\theta$ .



# Definição: Sufiência

► Em outras palavras (caso discreto)

$$f(y_1, ..., y_n | x_1; \theta) = \frac{f(y_1; \theta), ..., f(y_n; \theta)}{f_{X_1}(u_1(y_1, ..., y_n); \theta)}$$

Caso contínuo

$$f(y_1,\ldots,y_n|x_1;\theta) \propto \frac{f(y_1;\theta),\ldots,f(y_n;\theta)}{f_{X_1}(u_1(y_1,\ldots,y_n);\theta)}$$

Exemplo: Distribuição gamma.



# Critério da fatorização de Fisher-Neyman

A estatística  $X_1 = u_1(Y_1, ..., Y_n)$  é suficiente para  $\theta$  se e somente se

$$f(y_1; \theta) \dots f(y_n; \theta) = k_1(u_1(y_1, \dots, y_n); \theta) k_2(y_1, \dots, y_n),$$

onde  $k_2(y_1, \ldots, y_n)$  não depende de  $\theta$ .

Note que o lado esquerdo é a verossimilhança, assim

$$L(\theta) \propto k_1(X_1; \theta)$$
.

► Além disso, a log-verossimilhança é

$$I(\theta) = const + \log k_1(X_1; \theta).$$

▶ De onde segue que a função escore

$$U(\theta) = \frac{\partial}{\partial \theta} \log k_1(X_1; \theta).$$



#### Exemplos: Distribuição power

▶ Considere  $Y_1, ..., Y_n$  iid da distribuição power

$$f(y; \theta) = \theta y^{\theta-1}$$
 para  $0 < y < 1$ ,

onde  $\theta > 0$ . Considere a estatística  $\prod_{i=1}^{n} Y_i$ . Então,

$$f(y_1; \theta) \dots, f(y_n; \theta) = \theta^n \prod_{i=1}^n x_i^{\theta-1}.$$

Note que esta função depende dos dados apenas através de  $x_1 = \prod_{i=1}^n y_i$ , assim pelo Teorema da fatorização  $x_1$  é suficiente para  $\theta$ .

# Exemplos: Distribuição Weibull

► Considere a distribuição Weibull

$$f(y;\theta) = \theta y^{\theta-1} e^{-y^{\theta}}, \text{ for } y > 0.$$

► Log-verossimilhança

$$I(\theta) = n\log(\theta) + (\theta - 1)\sum_{i=1}^{n}\log y_i - \sum_{i=1}^{n}e^{\theta\log y_i},$$

► Função escore

$$U(\theta) = \frac{n}{\theta} + \sum_{i=1}^{n} \log y_i - \sum_{i=1}^{n} \log(y_i) e^{\theta \log y_i}.$$

 Neste caso a amostra completa é a menor estatística suficiente.



#### Esperança condicional

► Se X e Y são v.a e X tem esperança então

$$E(E(X|Y)) = E(X)$$

e se X tem variância, então

$$Var(X) = E(Var(X|Y)) + Var(E(X|Y)).$$

Disto, segue que

$$Var(X) \ge V(E(X|Y)).$$



#### Teorema de Rao-Blackwell

Seja  $X_1 = u_1(Y_1, ..., Y_n)$  uma estatística suficiente para  $\theta$  e seja  $X_2 = u_2(Y_1, ..., Y_n)$  um estimador não viciado para  $\theta$ . Então,

$$\tilde{\theta} = E(Y_2|Y1),$$

é também um estimador não viciado para  $\theta$  e  $Var(\tilde{\theta}) \leq Var(Y_2)$  para todo  $\theta \in \Omega$ .

► Demonstração.



#### Estimador não-viciado de variância minima

- ▶ **Definição:** A estatística  $X_2 = u_2(Y_1, ..., Y_n)$  é chamada estimador não-viciado de variância minima (MVUE) para  $\theta$  se  $X_2$  é não-viciado para  $\theta$  e se a variância de  $X_2$  é menor ou igual a variância de qualquer outro estimador não viciado para  $\theta$ .
- Rao-Blackwell teorema diz que o MVUE é sempre função de uma estatística suficiente.
- A existência de MVUE não é única e nem sempre existe.



# Teorema: EMV é função de uma estatística suficiente

- ▶ Se o EMV  $\hat{\theta}$  é unicamente determinado apartir de  $Y_1, \dots, Y_n$  e  $X_1 = u_1(Y_1, \dots, Y_n)$  é uma estatística suficiente, então  $\hat{\theta}$  é uma função de  $Y_1$ .
- ▶ Demonstração.
- ► Exemplo: Distribuição exponencial.



#### Familias completas

▶ **Definição**: A familia  $\{f_{X_1}(\cdot; \theta)\}$  é chamada completa se a condição

$$E(u(X_1)) = 0$$
, para  $todo\theta \in \Omega$ .

- ► Também podemos dizer que a estatística X<sub>1</sub> é completa.
- Exemplo: Distribuição exponencial, Bernoulli e normal.



#### Teorema de Lehmann-Scheffé

- ▶ Seja  $\tilde{\theta}$  um estimador não-viciado para  $\theta$ , tal que  $\tilde{\theta}$  é função de uma estatística suficiente e completa  $X_1$ . Então,  $\tilde{\theta}$  é o único MVUE de  $\theta$ .
- ▶ Demonstração.
- ► Exemplos: Família exponencial.

