Métodos Computacionais para Inferência Estatística

Capítulo 1 e 2 - Verossimilhança

Paulo Justiniano Ribeiro Jr. Wagner Hugo Bonat Elias Teixeira Krainski Walmes Marques Zeviani

LEG: Laboratório de Estatística e Geoinformação Universidade Federal do Paraná

20° SINAPE, 30-31/07/2012



Comentários

- Agradecimentos
- Recursos
 - Página: http://www.leg.ufpr.br/mcie
 - códigos e versões atualizadas !!!
- Principal público alvo: graduação a início de PG
- Motivações e Propósitos
- Experiências/exposição das gerações
- Facilidade de recursos computacionais e linguagens
- Uso de rotinas versus implementação/teste/ilustração/aprendizado
- Uso crítico e avaliação e apreciação das limitações de rotinas

Conteúdos

texto x apresentação

- Verossimilhança idéias e conceitos básicos e exemplos
- Modelos de regressão (GLM, Simplex, Subdisperso, Não Linear, Proc. Poisson não Hom.)
- Modelos de efeitos aleatórios (Espaciais, GLMM, Beta Longitudinal, TRI, Linear Dinâmico)
- Modelos dinâmicos
- (Inferência Bayesiana)
- Clonagem de dados
- INLA Integrated Nested Laplace Aproximation fundamentos
- INLA exemplos (regressão dinâmica e modelos espaço-temporais)
- Omissões do material / Omissões no material
- Foco: inferência por verossimilhança e alguns métodos numeros
- 💿 incursões eventuais em inferência Bayesiana «ロンベランベミンベミン

- Paradigmas
 - Frequentista (espaço amostral / Newman-Pearson)
 - Verossimilhança
 - Bayesiano





- Paradigmas
 - Frequentista (espaço amostral / Newman-Pearson)
 - Verossimilhança
 - Bayesiano
- Uma provocação à reflexão (Royall, 1997:)

"Fortunatelly we are not forced to choose either of these two evils, the sample-space dependence of the frequentists or the prior distribution of the Bayesians.





- Paradigmas
 - Frequentista (espaço amostral / Newman-Pearson)
 - Verossimilhança
 - Bayesiano
- Uma provocação à reflexão (Royall, 1997:)

"Fortunatelly we are not forced to choose either of these two evils, the sample-space dependence of the frequentists or the prior distribution of the Bayesians.

Likelihood methods avoid both sources of subjectivity. "

Diferentes perguntas:





- Paradigmas
 - Frequentista (espaço amostral / Newman-Pearson)
 - Verossimilhança
 - Bayesiano
- Uma provocação à reflexão (Royall, 1997:)

"Fortunatelly we are not forced to choose either of these two evils, the sample-space dependence of the frequentists or the prior distribution of the Bayesians.

- Diferentes perguntas:
 - O que devo fazer?





- Paradigmas
 - Frequentista (espaço amostral / Newman-Pearson)
 - Verossimilhança
 - Bayesiano
- Uma provocação à reflexão (Royall, 1997:)

"Fortunatelly we are not forced to choose either of these two evils, the sample-space dependence of the frequentists or the prior distribution of the Bayesians.

- Diferentes perguntas:
 - O que devo fazer?
 - O que os dados dizem?





- Paradigmas
 - Frequentista (espaço amostral / Newman-Pearson)
 - Verossimilhança
 - Bayesiano
- Uma provocação à reflexão (Royall, 1997:)

"Fortunatelly we are not forced to choose either of these two evils, the sample-space dependence of the frequentists or the prior distribution of the Bayesians.

- Diferentes perguntas:
 - O que devo fazer?
 - O que os dados dizem?
 - Em que devo acreditar?





Visitando um exemplo simples:

• População: $X \sim B(\theta)$





Visitando um exemplo simples:

• População: $X \sim B(\theta)$

• Amostra: x_1, \ldots, x_n





Visitando um exemplo simples:

- População: $X \sim B(\theta)$
- Amostra: x_1, \ldots, x_n
- O que podemos falar sobre θ ?
 - Qual a informação contida na amostra?
 - Consideram-se outras fontes de informação?





Visitando um exemplo simples:

- População: $X \sim B(\theta)$
- Amostra: x_1, \ldots, x_n
- O que podemos falar sobre θ ?
 - Qual a informação contida na amostra?
 - Consideram-se outras fontes de informação?
- informação na amostra resumida por $\left(n,y=rac{\sum_{i=1}^{n}x_{i}}{n}\right)$?





20° SINAPE, 30-31/07/2012

Espaço do Modelo

• O espaço definido pelo modelo (3-D)

$$\binom{n}{y}\theta^y(1-\theta)^{n-y}$$

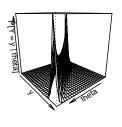


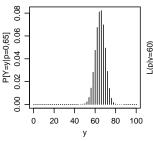


Espaço do Modelo

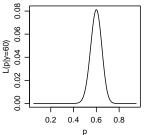
• O espaço definido pelo modelo (3-D)

$$\binom{n}{y}\theta^y(1-\theta)^{n-y}$$





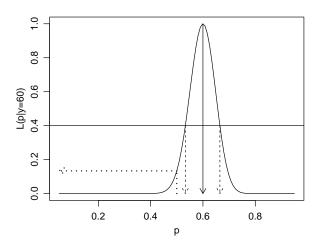
MCIE





Objetivos de Inferência

Objetivos de inferência e a função de verossimilhança







• função de verossimilhança probabilidade da amostra obtida para diferentes valores de θ





- melhor estimador





- função de verossimilhança probabilidade da amostra obtida para diferentes valores de θ
- melhor estimador
- conjunto de valores razoavelmente compatíveis com a amostra





- função de verossimilhança probabilidade da amostra obtida para diferentes valores de θ
- melhor estimador
- conjunto de valores razoavelmente compatíveis com a amostra
- decidir entre dois valores o mais compatível com a amostra





- função de verossimilhança probabilidade da amostra obtida para diferentes valores de θ
- melhor estimador
- conjunto de valores razoavelmente compatíveis com a amostra
- decidir entre dois valores o mais compatível com a amostra
- decidir se a amostra é compatível com certo valor θ_0 de interesse?





- função de verossimilhança probabilidade da amostra obtida para diferentes valores de θ
- melhor estimador
- conjunto de valores razoavelmente compatíveis com a amostra
- decidir entre dois valores o mais compatível com a amostra
- decidir se a amostra é compatível com certo valor θ_0 de interesse?
- suposições/pressupostos





- função de verossimilhança probabilidade da amostra obtida para diferentes valores de θ
- melhor estimador
- conjunto de valores razoavelmente compatíveis com a amostra
- decidir entre dois valores o mais compatível com a amostra
- decidir se a amostra é compatível com certo valor θ_0 de interesse?
- suposições/pressupostos
- relações e contrastes com outros métodos





Inferência Bayesiana

Extensão da definição do modelo

$$[Y|\theta] \sim B(n,\theta)$$

 $[\theta] \sim Pr(a,b)$ (priori)

permite obter (via teorema de Bayes)

$$[\theta|y] \sim \pi(a^*, b^*)$$
 (posteriori)

- Analogias diretas para estimação (pontual e intervalar),
- ... mas não para testes de hipótese (valores na posteriori sem analogias diretas com razão de verossimilhanças).





Função de Verossimilhança

Definição informal:

Dada pela expressão da distribuição conjunta de todas as v.a.'s observáveis (Y) o modelo. ou Distribuição conjunta de todas as v.a.'s especificadas no modelo, integrada sobre as não observáveis.

Notação: [·] (função de) distribuição de · Casos de particular interesse:

• Distribuições e modelos de regressão

 $[Y|\theta]$





Função de Verossimilhança

Definição informal:

Dada pela expressão da distribuição conjunta de todas as v.a.'s observáveis (Y) o modelo. ou Distribuição conjunta de todas as v.a.'s especificadas no modelo, integrada sobre as não observáveis.

Notação: [·] (função de) distribuição de · Casos de particular interesse:

• Distribuições e modelos de regressão

$$[Y|\theta]$$

 Modelos hierárquicos (mistos, efeitos aleatórios, longitudinais, espaciais, etc)

$$[Y|\theta] = \int [Y, b|\theta] db = \int [Y|b, \theta] [b|\theta] db$$





Função de Verossimilhança

Definição informal:

Dada pela expressão da distribuição conjunta de todas as v.a.'s observáveis (Y) o modelo. ou Distribuição conjunta de todas as v.a.'s especificadas no modelo, integrada sobre as não observáveis.

Notação: [·] (função de) distribuição de · Casos de particular interesse:

• Distribuições e modelos de regressão

$$[Y|\theta]$$

 Modelos hierárquicos (mistos, efeitos aleatórios, longitudinais, espaciais, etc)

$$[Y|\theta] = \int [Y, b|\theta] db = \int [Y|b, \theta] [b|\theta] db$$



• inclui Inf. Bayesiana com especificação de $[\theta]$

Expressão da Verossimilhança I

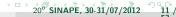
V.A. observável discreta (não há ambiguidade)

$$L(\theta) \equiv P_{\theta}[Y = y]$$

Exemplo: $Y \sim P(\lambda)$

$$L(\lambda) = \prod_{i=1}^{n} \frac{\exp\{-\lambda\}\lambda^{Y_i}}{Y_i!} = \frac{\exp\{-n\lambda\}\lambda^{\sum_{i=1}^{n} Y_i}}{\prod_{i=1}^{n} Y_i!}$$
$$\propto \exp\{-n\lambda\}\lambda^{\sum_{i=1}^{n} Y_i}$$





Expressão da Verossimilhança II

V.A. contínua: medição a certa precisão $(y_{il} \le y_i \le y_{iS})$

Forma mais geral

$$L(\theta) = P_{\theta}[y_{1l} \le y_1 \le y_{1S}, \dots, y_{nl} \le y_1 \le y_{nS}]$$





Expressão da Verossimilhança II

V.A. contínua: medição a certa precisão $(y_{il} \le y_i \le y_{iS})$

Forma mais geral

$$L(\theta) = P_{\theta}[y_{1l} \le y_1 \le y_{1S}, \dots, y_{nl} \le y_1 \le y_{nS}]$$

Sob independência

$$L(\theta) = P_{\theta}[y_{1I} \leq y_1 \leq y_{1S}], \dots, P_{\theta}[y_{nI} \leq y_1 \leq y_{nS}] = \prod_{i=1}^{n} P_{\theta}[y_{iI} \leq y_1 \leq y_$$





Expressão da Verossimilhança II

V.A. contínua: medição a certa precisão $(y_{il} \le y_i \le y_{iS})$

Forma mais geral

$$L(\theta) = P_{\theta}[y_{1l} \le y_1 \le y_{1S}, \dots, y_{nl} \le y_1 \le y_{nS}]$$

Sob independência

$$L(\theta) = P_{\theta}[y_{1I} \leq y_1 \leq y_{1S}], \dots, P_{\theta}[y_{nI} \leq y_1 \leq y_{nS}] = \prod_{i=1}^{n} P_{\theta}[y_{iI} \leq y_1 \leq y_1$$

• Grau de precisão comum, $(y_i - \delta/2 \le Y_i \le y_i + \delta/2)$;

$$L(\theta) = \prod_{i=1}^n P_{\theta}[y_i - \delta/2 \leq Y_i \leq y_i + \delta/2] = \prod_{i=1}^n \int_{y_i - \delta/2}^{y_i + \delta/2} f(y_i, \theta) d(y_i).$$

Expressão da Verossimilhança II (cont)

• alto grau de precisão (δ é pequeno em relação a variabilidade dos dados)

$$L(\theta) \approx \left(\prod_{i=1}^n f(y_i, \underline{\theta})\right) \delta^n,$$





Expressão da Verossimilhança II (cont)

• alto grau de precisão (δ é pequeno em relação a variabilidade dos dados)

$$L(\theta) \approx \left(\prod_{i=1}^n f(y_i, \underline{\theta})\right) \delta^n,$$

ullet e se δ não depende dos valores dos parâmetros

$$L(\theta) \approx \prod_{i=1}^{n} f(y_i, \underline{\theta})$$





Expressão da Verossimilhança II (cont)

• alto grau de precisão (δ é pequeno em relação a variabilidade dos dados)

$$L(\theta) \approx \left(\prod_{i=1}^n f(y_i, \underline{\theta})\right) \delta^n,$$

ullet e se δ não depende dos valores dos parâmetros

$$L(\theta) \approx \prod_{i=1}^{n} f(y_i, \underline{\theta})$$

• observações não independentes - densidade multivariada:

$$L(\theta) \approx f(y, \underline{\theta})$$





Verossimilhança e Informação

Considere $Y \sim N(\theta, 1)$ e as as seguintes observações.

- ① x = 2.45
- 0.9 < x < 4
- **3** somente o máximo de uma amostra de tamanho cinco é fornecido $x_{(5)} = 3.5$





Verossimilhança e Informação

Considere $Y \sim N(\theta, 1)$ e as as seguintes observações.

- 0 x = 2.45
- 0.9 < x < 4
- 3 somente o máximo de uma amostra de tamanho cinco é fornecido $x_{(5)}=3.5$

Verossimilhança:

$$L(\theta; x) = \phi(x - \theta) \equiv \frac{1}{\sqrt{2\pi}} \exp\{-\frac{1}{2}(x - \theta)^2\};$$

$$L_1 = L(\theta; x = 2.45) = \phi(x - \theta) = \frac{1}{\sqrt{2\pi}} \exp\{-\frac{1}{2}(2.45 - \theta)^2\};$$

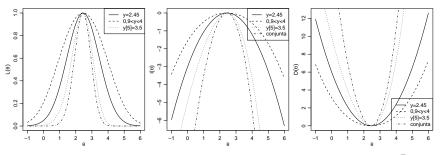
$$L_2 = L(\theta; 0.9 < x < 4) = \Phi(4 - \theta) - \Phi(0.9 - \theta);$$

$$L_3 = L(\theta; x_{(5)} = 3.5) = n\{\Phi(x_{(n)} - \theta)\}^{n-1}\phi(x_{(n)} - \theta).$$

Para última - argumento multinomial e com

$$F(y) = P(X_{\{n\}} \le y) = P[X_{\{i\}} < y \ \forall i \ne n \ e \ X_{\{n\}} = y]$$

Verossimilhança e Informação (cont)







Formas alternativas

Verossimilhança:

$$L(\theta)$$

Verossimilhança Relativa:

$$LR(\theta) = \frac{L(\theta)}{L(\hat{\theta})}$$

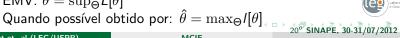
log-Verossimilhança:

$$I(\theta) = \log\{L(\theta)\}\$$

Deviance:

$$D(\theta) = -2\log\{LR[\theta]\} = -2\{I[\theta] - I[\hat{\theta}]\}$$

EMV: $\hat{\theta} = \sup_{\Theta} L[\theta]$





Exemplo: distribuição Poisson

$$L[\theta] = \frac{\exp\{-n\lambda\}\lambda^{\sum_{i=1}^{n} Y_i}}{\prod_{i=1}^{n} Y_i!}$$

$$LR[\theta] = \exp\{-n(\lambda - \hat{\lambda})\}(\lambda/\hat{\lambda})^{n\overline{Y}}$$

$$I[\theta] = -n\lambda + n\overline{Y}\log(\lambda) - \sum_{i=1}^{n}\log(Y_i!)$$

$$D(\theta) = 2n\{(\lambda - \hat{\lambda}) - \overline{Y}\log(\lambda/\hat{\lambda})\}$$

$$\hat{\theta} = \overline{Y}$$



Exemplo: Distribuição Poisson

Código 1

Código 2

Exemplo: Distribuição Poisson (cont)

```
mll <- veroPois(emv, amostra=am, tipo="logL")</pre>
 curve(veroPois(x, amostra=am, tipo="dev", maxlogL=mll), 8, 11,
         ylab=expression(D(lambda)), xlab=expression(lambda))
                     LR(2)
                        9.0
                                                                 (3)
3
                                           3
  2e-22
                                              50.5
                        0.2
    8.0
         9.0
              10.0
                   11.0
                          8.0
                               9.0
                                    10.0
                                         11.0
                                                8.0
                                                     9.0
                                                          10.0
                                                              11.0
                                                                      8.0
                                                                           9.0
                                                                               10.0
                                                                                    11.0
```





Funções de Interesse

- Função escore: $U(\theta) = I'(\theta)$
- Hessiano/Informação observada: $I_O(\theta) = -H(\theta) = -I''(\theta)$
- Informação Esperada: $I_E(\theta) = E_Y[I_O(\theta)]$
- Estimadas: $I_O(\hat{\theta})$ e $I_E(\hat{\theta})$





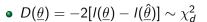
Funções de Interesse

- Função escore: $U(\theta) = I'(\theta)$
- Hessiano/Informação observada: $I_O(\theta) = -H(\theta) = -I''(\theta)$
- Informação Esperada: $I_E(\theta) = E_Y[I_O(\theta)]$
- Estimadas: $I_O(\hat{\theta})$ e $I_E(\hat{\theta})$

Propriedades assintóticas:

- $\hat{\underline{\theta}} \sim NM_d(\underline{\theta}, I_E(\underline{\theta})^{-1})$
- Assintoticamente equivalentes:

$$\hat{\underline{\theta}} \sim NM_d(\underline{\theta}, I_E(\hat{\underline{\theta}})^{-1})$$
 $\hat{\underline{\theta}} \sim NM_d(\underline{\theta}, I_O(\underline{\theta})^{-1})$
 $\hat{\underline{\theta}} \sim NM_d(\underline{\theta}, I_O(\hat{\underline{\theta}})^{-1}).$





Exemplo: Distribuição Poisson (cont)

$$L(\lambda) = \prod_{i=1}^{n} \frac{\exp\{-\lambda\}\lambda^{Y_i}}{Y_i!} = \frac{\exp\{-n\lambda\}\lambda^{\sum_{i=1}^{n} Y_i}}{\prod_{i=1}^{n} Y_i!}$$

$$I(\lambda) = -n\lambda + (\sum_{i=1}^{n} Y_i)\log(\lambda) - \sum_{i=1}^{n} \log Y_i!$$

$$U(\lambda) = -n + \frac{\sum_{i=1}^{n} Y_i}{\lambda}$$

$$U(\hat{\lambda}) = 0 \longrightarrow \hat{\lambda} = \frac{\sum_{i=1}^{n} Y_i}{n} = \overline{Y}$$

$$I_O(\lambda) = \frac{\sum_{i=1}^{n} Y_i}{\lambda^2}; I_E(\lambda) = \frac{n}{\lambda}; I_O(\hat{\lambda}) = I_E(\hat{\lambda}) = \frac{n^2}{\sum_{i=1}^{n} Y_i}$$

$$V(\hat{\lambda}) = I_E(\lambda)^{-1} \approx I_O(\lambda)^{-1} \approx I_O(\hat{\lambda})^{-1} = I_E(\hat{\lambda})^{-1}$$

Exemplo: Distribuição Poisson (cont)

Função escore:

```
UPois <- function(lambda, amostra){
  return(with(amostra, n - soma/lambda))
}</pre>
```

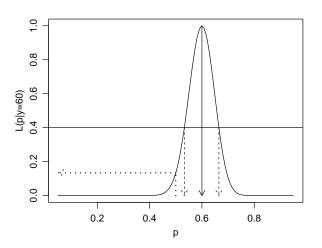
Hessiano (informação estimada):

```
HPois <- function(lambda, amostra){
  return(with(amostra, soma/lambda^2))
}</pre>
```



Estimação

Objetivos de inferência e a função de verossimilhança





Obtendo o EMV

- analiticamente: estudando comportamento de $I(\theta)$ ou resolvendo $U(\theta) = 0$
- numericamente (otimização/aproximações numéricas)
 - Solução da(s) equação(ões) de estimação (função escore)
 - com uso de derivadas (ex: Newton-Raphson)
 - sem uso de derivadas (ex: Brent)
 - Maximização da função de (log)-verossimilhança
- Outros (ex: EM)
- Simulação (ex: verossimilhança Monte Carlo, data-cloning, ...)
- Aproximações da verossimilhança (pseudo-verossimilhanças)





Estimadores e Inferência

- Análogos para distribuições posteriori em Inferência Bayesiana
- maximização numérica: mais comum em EMV
- simulação: mais usual em Inferência Bayesiana





EMV

Newton Raphson: expansão (Taylor) de 1^a ordem de $U(\theta)$:

$$\lambda^{r+1} = \lambda^r - \frac{U(\lambda)}{H(\lambda)}$$

```
maxit <- 100; lambdaNR <- 5; iter <- 0; d <- 1
while(d > 1e-12 & iter <= maxit){
    lambdaNR.new <-
        lambdaNR - UPois(lambdaNR, am)/HPois(lambdaNR, am)
    d <- abs(lambdaNR - lambdaNR.new)
    lambdaNR <- lambdaNR.new; iter <- iter + 1
}
c(lambdaNR, iter)</pre>
```

Variante - Fisher scoring: $-H(\lambda) = I_E(\lambda)$





Exemplo: Distribuição Poisson (cont)

• Solução de equação $U(\theta) = 0$:

```
uniroot(UPois, interval=range(y), amostra=am)$root
```

Maximização da verossimilhança

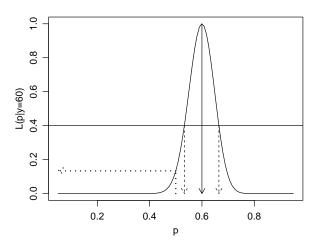
- uso do gradiente: argumento gr = Upois
- pode retornar hessiano numérico ($I_O(\hat{\theta})$ obtido numericamente)





Intervalo de Confiança

Objetivos de inferência e a função de verossimilhança





Intervalo de confiança

- Região definida por corte na função de verossimilhança
 - $LR(\theta) \geq r$
 - $l(\theta) \geq c$
 - $D(\theta) \leq c^*$





Intervalo de confiança

- Região definida por corte na função de verossimilhança
 - $LR(\theta) \geq r$
 - $I(\theta) \geq c$
 - $D(\theta) \leq c^*$
- Definição do ponto de corte
 - a) interpretação de evidência relativa em $LR(\theta)$
 - b) comportamento assintótico $D(\theta) \sim \chi_p^2$
 - c) interpretação probabilística direta em inf. Bayesiana (quantis ou HPD)
 - d) evidência por analogia sobre diferenças em $I(\theta)$



Intervalo de confiança

- Região definida por corte na função de verossimilhança
 - $LR(\theta) \geq r$
 - $I(\theta) \geq c$
 - $D(\theta) \leq c^*$
- Definição do ponto de corte
 - a) interpretação de evidência relativa em $LR(\theta)$
 - b) comportamento assintótico $D(heta) \sim \chi_p^2$
 - c) interpretação probabilística direta em inf. Bayesiana (quantis ou HPD)
 - d) evidência por analogia sobre diferenças em $I(\theta)$
- Relações entre (a) e (b)

r	С	c *	$P[Z < \sqrt{c^*}]$
50%	0,693	1,386	0,761
26%	1.661	3,321	0,899
15%	1,897	3,794	0,942
3,6%	3,324	6,648	0,990



analogia...







Limites do Intervalo

- Solução de equação (analítica ou numérica)
 - $LR(\theta) = r$ • $I(\theta) = c$
 - $D(\theta) = c^*$



Limites do Intervalo

- Solução de equação (analítica ou numérica)
 - $LR(\theta) = r$
 - $I(\theta) = c$
 - $D(\theta) = c^*$
- Aproximação quadrática (Taylor)

$$D(\theta) = -2[I(\theta) - I(\hat{\theta})] =$$

$$= -2\left\{ [I(\hat{\theta}) + (\theta - \hat{\theta})I'(\hat{\theta}) + \frac{1}{2}(\theta - \hat{\theta})^2I''(\hat{\theta})] - I(\hat{\theta}) \right\}$$

$$D(\theta) = -(\theta - \hat{\theta})^2I''(\hat{\theta}) \le c^*$$

$$\tilde{\theta} = \hat{\theta} \pm \sqrt{\frac{c^*}{I''(\hat{\theta})}}$$





Limites do Intervalo

- Solução de equação (analítica ou numérica)
 - $LR(\theta) = r$
 - $I(\theta) = c$
 - $D(\theta) = c^*$
- Aproximação quadrática (Taylor)

$$D(\theta) = -2[I(\theta) - I(\hat{\theta})] =$$

$$= -2\left\{ [I(\hat{\theta}) + (\theta - \hat{\theta})I'(\hat{\theta}) + \frac{1}{2}(\theta - \hat{\theta})^2I''(\hat{\theta})] - I(\hat{\theta}) \right\}$$

$$D(\theta) = -(\theta - \hat{\theta})^2I''(\hat{\theta}) \le c^*$$

$$\tilde{\theta} = \hat{\theta} \pm \sqrt{\frac{c^*}{I''(\hat{\theta})}}$$

equivalência com à Distribuição assintótica: $\hat{\underline{\theta}} \sim NM_d(\underline{\theta}, I_E(\underline{\theta}))$

Exemplo: Exponencial (i.i.d.)

 $\hat{\theta} = 1/\bar{v}$

$$f(y_i, \theta) = \theta \exp\{-\theta y_i\} \quad y > 0 \; ; \; \theta > 0$$

$$F(y_i, \theta) = 1 - \exp\{-\theta y_i\} \quad y > 0 \; ; \; \theta > 0$$

$$L(\theta) = \theta^n \exp\{-\theta n \overline{y}\}$$

$$I(\theta) = n \log(\theta) - \theta n \overline{y}$$

$$U(\theta) = \frac{n}{\theta} - n \overline{y}$$

$$H(\theta) = -\frac{n}{\theta^2} \; \text{(depende do valor de } \theta!!)$$





Intervalos de confiança

① Corte na deviance: (solução apenas numericamente)

$$D(\theta) = 2n[\log(\hat{\theta}/\theta) + \overline{y}(\theta - \hat{\theta})] \le c^*$$





Intervalos de confiança

Corte na deviance: (solução apenas numericamente)

$$D(\theta) = 2n[\log(\hat{\theta}/\theta) + \overline{y}(\theta - \hat{\theta})] \le c^*$$

Aproximação quadrática:

$$D(heta) pprox n \left(rac{ heta - \hat{ heta}}{\hat{ heta}}
ight)^2$$
 $\left(\hat{ heta}_L pprox \hat{ heta}(1 - \sqrt{c^*/n}) \;,\;\; \hat{ heta}_U pprox \hat{ heta}(1 + \sqrt{c^*/n})
ight)$





Intervalos de confiança

Corte na deviance: (solução apenas numericamente)

$$D(\theta) = 2n[\log(\hat{\theta}/\theta) + \overline{y}(\theta - \hat{\theta})] \le c^*$$

Aproximação quadrática:

$$D(heta) pprox n \left(rac{ heta - \hat{ heta}}{\hat{ heta}}
ight)^2$$
 $\left(\hat{ heta}_L pprox \hat{ heta}(1 - \sqrt{c^*/n}) \;,\;\; \hat{ heta}_U pprox \hat{ heta}(1 + \sqrt{c^*/n})
ight)$

Distribuição assintótica: $I_F^{-1}(\theta) \approx I_O^{-1}(\hat{\theta}) = \hat{\theta}^2/n$ $\hat{\theta} \pm z_{\frac{\alpha}{2}} \sqrt{V(\hat{\theta})}$

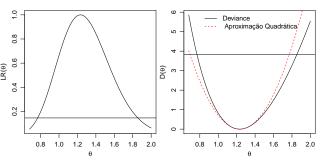


$$\hat{\theta}_{I} = \hat{\theta} - z_{\alpha} \hat{\theta} / \sqrt{n} \text{ e} \quad \hat{\theta}_{II} = \hat{\theta} + z_{20} \hat{\theta} \sin \sqrt{n} \text{e}, 30.31/07/2012} \quad 33.73 \text{ MCIE}$$

Exemplo: Distribuição Exponencial (cont)

```
ICdevExp <- function(theta, theta.hat, y, nivel=0.95){
  n <- length(y)
  dv <- 2*n*( log( theta.hat/theta) + mean(y)*(theta- theta.hat))
  return(dv - qchisq(nivel,df=1))
}</pre>
```

```
require(rootSolve)
uniroot.all(ICdevExp, interval=c(0,10), theta.hat=1/mean(y),y=y)
```





Reparametrização

$$\phi = g(\theta)$$

- $\hat{\phi} = g(\hat{\theta})$
- IC por corte: $(\hat{\phi}_I, \hat{\phi}_S) = (g(\hat{\theta}_I), g(\hat{\theta}_S))$
- Assintóticamente: $\hat{\phi} = g(\hat{\theta}) \sim N(\phi, [g'(\theta)]^2 [I_E(\theta)]^{-1})$
- Método delta:

$$\operatorname{Var}(\hat{\phi}) = [g'(\theta)]^2 [I_E(\theta)]^{-1} \longrightarrow \left[\operatorname{se}(\hat{\phi}) = |g'(\theta)| [I_E(\theta)]^{-1/2} \right]$$

• Se transformação $g(\cdot)$ é não linear, invariância não é válida para aproximação quadrática

$$\{g(\hat{\theta}_{I}),g(\hat{\theta}_{S})\} = \{g(\hat{\theta} - z_{\alpha/2}[I_{E}(\hat{\theta})]^{-1/2}),g(\hat{\theta} + z_{\alpha/2}[I_{E}(\hat{\theta})]^{-1/2})\} \neq$$

$$(\tilde{\phi}_{I},\tilde{\phi}_{S}) = \{g(\hat{\theta}) - z_{\alpha/2}[g'(\theta)|[I_{E}(\hat{\theta})]^{-1/2},g(\hat{\theta}) + z_{\alpha/2}[g'(\theta)|[I_{E}(\hat{\theta})]^{-1/2}\}$$

• $I(\phi)$ é menos assimétrica: $(\tilde{\phi}_I, \tilde{\phi}_S)$ $I(\theta)$ é menos assimétrica: $(g(\tilde{\phi}_I), g(\tilde{\phi}_S))$



Recomendações

- Melhor abordagem: (mais geral e acurácia)
 IC's baseados verossimilhança/deviance (muitas vezes só obtidos numericamente)
- Intervalos assintóticos (utilizam $se(\hat{\theta})$, obtenção a partir da aproximação quadrática, formas fechadas)
- Escolher parametrização da função que forneça uma boa aproximação quadrática
- IC's para funções dos parâmetros: obtenção pelo método delta ou direta se aproximadamente quadrática





Condições de regularidade

- Θ é finito dimensional e θ é interior a Θ
- primeiras três derivadas de $I(\theta)$ na vizinhança de θ
- ullet amplitude não depende de heta
- $I(\theta) \approx \text{ quadrática para } n \to \infty$, passando a depender apenas da posição e curvatura no EMV
- ... $I_E(\theta)$ precisa ser inversível





Reparametrização

$$\phi = P[Y \le u] = 1 - \exp\{-\theta u\}$$

- Obter $se(\hat{\phi})$
- Três intervalos possíveis:

$$egin{aligned} (\hat{\phi}_I, \hat{\phi}_S) : (g(\hat{ heta}_I), g(\hat{ heta}_S)) \ & (ilde{\phi}_I, ilde{\phi}_S) : \hat{\phi} \pm z_{lpha/2} se(\hat{\phi}) \ & (1 - \exp\{- ilde{ heta}_S u\}, 1 - \exp\{- ilde{ heta}_S u\}) : (g(ilde{ heta}_I), g(ilde{ heta}_S)) \end{aligned}$$

• Comparação gráfica das funções e das taxas de cobertura (simuação)

Exemplo: Distribuição Exponencial (cont)

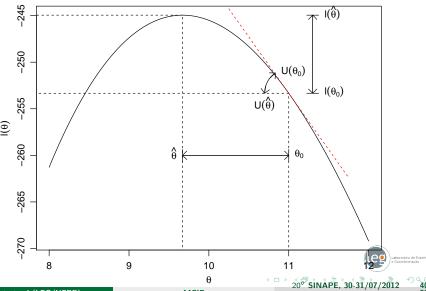
Redefinindo

```
ICdevExp <- function(theta, theta.hat, y, nivel=0.95){</pre>
   n <- length(v)
   dv <- 2*n*( log( theta.hat/theta) + mean(y)*(theta- theta.hat))
   return(dv - qchisq(nivel,df=1))
require(rootSolve)
uniroot.all(ICdevExp, interval=c(0,10), theta.hat=1/mean(y), y=y)
       ICdevExp <- function(theta, amostra, nivel=0.95){</pre>
          ## amostra é um vetor com elementos n e mean(y), nesta ordem
          n <- amostra[1]
          med <- amostra[2]
          dv \leftarrow 2*n*(-\log(med*theta) + med*theta - 1)
          return(dv - qchisq(nivel, df=1))
```

```
am <- c(length(y), mean(y))
uniroot.all(ICdevExp, interval=c(0,10), amostra=am)</pre>
```



Teste de Hipótese



Teste de Hipótese

Teste razão de verossimilhanca

```
trv <- function(Est, HO, alpha, ...){</pre>
  critico <- qchisq(1-alpha, df=1)</pre>
  est.calc <- Est(H0, ...)
  print(ifelse(est.calc < critico, "Aceita HO", "Rejeita HO"))</pre>
  return(c(est.calc,critico))}
```

Teste Wald

```
wald <- function(HO, EMV, V.EMV, alpha){</pre>
  critico <- qnorm(1-alpha/2)</pre>
  Tw <- (EMV - HO)/sqrt(V.EMV)
  print(ifelse(Tw < critico, "Aceita HO", "Rejeita HO"))</pre>
 return(c(Tw,critico))
```

Teste Escore

```
escore <- function(HO, U, Ie, alpha, ...){
  critico <- qnorm(1-alpha/2)</pre>
  Te <- U(H0,...)/sqrt(Ie(H0,...))
  print(ifelse(Te < critico, "Aceita HO", "Rejeita HO"))</pre>
  return(c(Te.critico))
                                                  20° SINAPE. 30-31/07/2012
```

Exemplo: Poisson

```
TRV
```

```
Est <- function(H0, x){
   n \leftarrow length(x)
   EMV \leftarrow mean(x)
   lv \leftarrow 2*n*((HO - EMV) + EMV*log(EMV/HO))
return(lv)
trv(Est = Est, H0=8, alpha = 0.05, x=x)
Wald
wald(HO=8, EMV = mean(x), V.EMV = mean(x)/length(x), alpha=0.05)
Escore
fc.escore <- function(lambda,x){</pre>
   n <- length(x)
   esco <- -n + sum(x)/lambda
   return(esco)}
Ie <- function(lambda.x){</pre>
   n \leftarrow length(x)
   I <- n/lambda
   return(I)}
escore(H0 = 8, U = fc.escore, Ie = Ie, alpha=0.05, x=x)
```

Exemplo: Distribuição Normal

log-Verossimilhança

$$I(\mu,\sigma) = -\frac{n}{2}\log 2\pi - n\log \sigma - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i - \mu)^2.$$

Escore

$$U(\mu) = \frac{\partial I(\mu, \sigma)}{\partial \mu} = \frac{\sum_{i=1}^{n} y_i}{\sigma^2} - \frac{n\mu}{\sigma^2}$$

$$U(\sigma) = -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{i=1}^n (y_i - \mu)^2.$$

EMV

$$\hat{\mu} = \frac{\sum_{i=1}^{n} y_i}{n}$$
 e $\hat{\sigma^2} = \frac{\sum_{i=1}^{n} (y_i - \mu)^2}{n}$.

Informação

$$I_O(\hat{\mu},\hat{\sigma})=\left[egin{array}{c} rac{n}{\hat{\sigma}^2} & 0 \ 0 & rac{2n}{\hat{\sigma}^2} \end{array}
ight].$$

MCIE

MCIE

MCIE

MOIS SINAPE, 30-31/07/2012

43 / 53



Intervalos de confiança

Conjuntos

corte

$$D(\mu, \sigma) = 2[n \log \left(\frac{\sigma}{\hat{\sigma}}\right) + \frac{1}{2\sigma^2} \sum_{i=1}^{n} (y_i - \mu)^2 - \frac{1}{2\hat{\sigma}^2} \sum_{i=1}^{n} (y_i - \hat{\mu})]$$

• elipse (aproximação quadrática)

$$D(\mu, \sigma) \approx (\underline{\theta} - \underline{\hat{\theta}})^{\top} I_o(\underline{\hat{\theta}}) (\underline{\theta} - \underline{\hat{\theta}}).$$

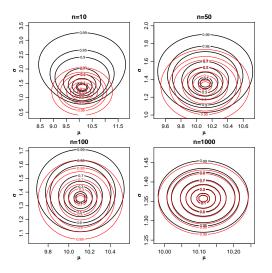
assintótico

$$\begin{bmatrix} \hat{\mu} \\ \hat{\sigma} \end{bmatrix} \sim \textit{NM}_2 \left(\begin{bmatrix} \mu \\ \sigma \end{bmatrix}, \begin{bmatrix} \hat{\sigma}^2/n & 0 \\ 0 & \hat{\sigma}^2/2n \end{bmatrix} \right)$$





Exemplo: Distribuição Normal (cont)







Intervalos de confiança

Parâmetros de interesse e de inconveniência (nuisance): (θ, ψ) Soluções usuais:

- Condicionando no EMV : $L(\theta) = L(\theta, \hat{\psi}) \equiv [Y|\theta, \hat{\psi}]$
- ullet Verossimilhança Perfilhada : $\mathit{L}(\theta) \equiv \mathit{L}[\theta, \hat{\psi}_{\theta}]$
- Verossimilhanças marginais integradas Bayesianas : $L(\theta) = \int [Y|\theta,\psi][\psi]d\psi$





Intervalos de confiança

Parâmetros de interesse e de inconveniência (nuisance): (θ, ψ) Soluções usuais:

- Condicionando no EMV : $L(\theta) = L(\theta, \hat{\psi}) \equiv [Y|\theta, \hat{\psi}]$
- ullet Verossimilhança Perfilhada : $\mathit{L}(heta) \equiv \mathit{L}[heta, \hat{\psi}_{ heta}]$
- Verossimilhanças marginais integradas Bayesianas :

$$L(\theta) = \int [Y|\theta,\psi][\psi]d\psi$$

Exemplo Normal: $1/\sigma^2 \sim G(a,b)$

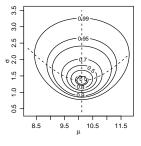
$$f(y|\mu) = \frac{\Gamma(n/2+1)}{\pi^{n/2}\Gamma(a)(\sum_{i}(y_{i}-\mu)^{2}+2b)^{n/2+a}}$$

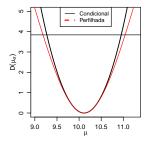
Integrações analíticas e por simulação

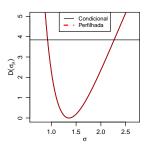




Exemplo: Distribuição Normal (cont)











Exemplo: Distribuição Normal (cont)

```
pl.mu <- function(sigma, mu, dados){</pre>
    pll <- sum(dnorm(dados, mean=mu, sd=sigma, log=TRUE))
    return(pll)}
##
pl.sigma <- function(mu, sigma, dados){</pre>
    pll <- sum(dnorm(dados, mean=mu, sd=sigma, log=TRUE))
    return(pll)}
```

```
grid.mu <- seq(9, 11.3, length=200)
grid.sigma \leftarrow seq(0.65, 2.7, length=200)
## Condicionais:
mu.cond <- sapply(grid.mu, pl.sigma, sigma=sqrt(var(y10)*9/10), dados=y10)
sigma.cond <- sapply(grid.sigma, pl.mu, mu=mean(y10), dados=y10)
mu.perf <- matrix(0, nrow=length(mu), ncol=2)</pre>
for(i in 1:length(mu)){
mu.perf[i,] <- unlist(optimize(pl.mu,c(0,200),</pre>
                      mu=mu[i],dados=y10,maximum=TRUE))}
sigma.perf <- matrix(0, nrow=length(sigma), ncol=2)</pre>
for(i in 1:length(sigma)){
sigma.perf[i,] <- unlist(optimize(pl.sigma,c(0,1000),
                 sigma=sigma[i],dados=y10,maximum=TRUE))}
```



Exemplo: Distribuição Normal (Dados intervalares)

Dados intervalares:

observações "pontuais": 72,6 81,3 72,4 86,4 79,2 76,7 81,3;

observações intervalares:

uma observação com valor acima de 85, uma observação com valor acima de 80, quatro observações com valores entre 75 e 80, seis observações com valores abaixo de 75.

Contribuições para verossimilhança

$$L(\underline{\theta}) = f(y_i)$$
 para y_i pontual,

$$L(\underline{\theta}) = 1 - F(85)$$
 para $y_i > 85$,

$$L(\underline{\theta}) = 1 - F(80)$$
 para $y_i > 80$,

$$L(\underline{\theta}) = F(80) - F(75)$$
 para 75 < $y_i < 80$,

$$L(\theta) = F(75)$$
 para $y_i < 85$.



Dados intervalares (cont)

```
nllnormI <- function(par, xp, XI) {
    ll1 <- sum(dnorm(xp, mean = par[1], sd = par[2], log = T))
    L2 <- pnorm(XI, mean = par[1], sd = par[2])
    l12 <- sum(log(L2[, 2] - L2[, 1]))
    return(-(ll1 + ll2))
}

[,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10] [,11] [,12]

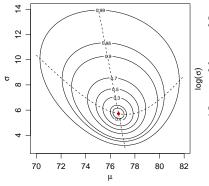
    85    80    75    75    75    75    -Inf -Inf -Inf -Inf -Inf -Inf -Inf</pre>
```

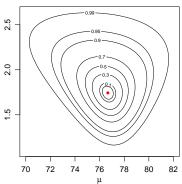


Dados intervalares (cont)

Função deviance genérica.

```
devFun <- function(theta, est, llFUN, ...){
  return(2 * (11FUN(theta, ...) - llFUN(est, ...)))
}
devSurf <- Vectorize(function(x,y, ...) devFun(c(x,y), ...))</pre>
```







Dados intervalares (cont)

Código mais geral e cuidadoso



Outros exemplos (texto)

- AR1
- Outro exemplo de reparametrização
- Gamma
- Binomial Negativa
- Processo de Poisson não-homogêneo
- Modelo espacial Geoestatístico
- Códigos Genéricos:
 - mle (stat4) e mle2 (bbmle)
 - profile e confint



