Métodos Computacionais para Inferência Estatística

Capítulo 2 - Modelos de Regressão

Wagner Hugo Bonat Paulo Justiniano Ribeiro Jr Elias Teixeira Krainski Walmes Marques Zeviani

LEG: Laboratório de Estatística e Geoinformação Universidade Federal do Paraná

30 de julho de 2012



Objetivo e estrutura


- Modelos de regressão;
- Regressão de Poisson;
- Regressão Contagem-Gama (contagem com subdispersão);
- Regressão não linear (reparametrizações do modelo logístico);






Objetivo e estrutura

 Procura-se explicar a variação em uma variável aleatória dado conhecimento sobre covariáveis;






Modelo de regressão linear simples








Regressão de Poisson (GLM Poisson)








Regressão logística (GLM Binomial)








Regressão Beta



Regressão não linear com heterogeneidade de variância





Regressão de Poisson: verossimilhança

Função de probabilidade

$$Pr(Y = y) = \frac{\exp{\{-\lambda\}\lambda^y}}{y!}, \quad \lambda > 0, \quad y = 0, 1, 2, ...;$$

Momentos

$$E(Y) = \lambda$$
 e $V(Y) = \lambda$;

• Função de relação

$$\lambda = g(x, \beta) : \mathbb{R} \to \mathbb{R}_*^+,$$

Usualmente

$$\lambda = \exp\{X\beta\}.$$





Regressão de Poisson: log-verossimilhança

Função de verossimilhanca

$$L(\lambda; y) = \prod_{i=1}^{n} \frac{\exp\{-\lambda\}\lambda_{i}^{y}}{y_{i}!};$$

• Função de log-verossimilhança $\ell(.) = \log L(.)$, $\lambda_i = \exp\{x_i^{\top} \beta\}$.

$$\ell(\beta; y, X) = \sum_{i=1}^{n} -\exp\{x_i^{\top}\beta\} + y_i x_i^{\top}\beta - \log(y_i!);$$

Em forma vetorial

$$\ell(\beta; y, X) = -1^{\top} \exp\{X\beta\} + y^{\top}X\beta - 1^{\top} \log(y!);$$



30 de julho de 2012

Regressão de Poisson: função escore e hessiana

ℓ(.) vetorial

$$\ell(\beta; y, X) = -1^{\top} \exp\{X\beta\} + y^{\top}X\beta - 1^{\top} \log(y!);$$

• Função escore $U(\beta) = \frac{\partial \ell}{\partial \beta}$,

$$U(\beta) = (y - \exp\{X\beta\})^{\top} X;$$

• Matriz de informação observada $I_o(\beta) = \frac{\partial U}{\partial \beta}$,

$$I_o(\beta) = X^{\top}(diag(\exp\{X\beta\}))X;$$





Regressão de Poisson: simulação

Simulando dados

$$Y|x \sim \mathsf{Poisson}(\lambda)$$

 $\lambda = \exp{\{\beta_0 + \beta_1 x\}}$





> set.seed(123)

Regressão de Poisson: cálculo do escore e hessiana

Vetor escore e matriz hessiana

```
> escore <- function(par, formula, dados){
    X <- model.matrix(as.formula(formula), data=dados)</pre>
    esco <- t(dados$y-exp(X%*%c(par[1], par[2])))%*%X
    return(as.vector(esco))
                                                   U(\beta) = (y - \exp\{X\beta\})^{\top} X
> hessiano <- function(par, formula, dados){
    X <- model.matrix(as.formula(formula), data=dados)
    mat <- diag(length(dados$y))
    diag(mat) <- -exp(X%*%c(par[1], par[2]))
    H < - t(X) %*%mat%*%X
    return(H)
                       I_o(\beta) = -X^{\top}(diag(\exp\{X\beta\}))X
> hessiano <- function(par, formula, dados){
    X <- model.matrix(as.formula(formula), data=dados)</pre>
    H <- crossprod(X*-(exp(drop(X%*%par))), X)
    return(H)
                                              → +eficiente
```



Regressão de Poisson: estimação

estimação pelo Newton-Raphson

```
> estimativa <- NewtonRaphson(initial=c(0,0), escore=escore, hessiano=hessiano, max.iter=100, n.dim=2, formula="~cov", dados=dados10)

[1] 2.2285674 0.4276769
```

informação

intervalos de confiança

```
> desvio.padrao <- sqrt(diag(solve(Io)))
> estimativa[1]+c(-1,1)*qnorm(0.975)*desvio.padrao[1]
> estimativa[2]+c(-1,1)*qnorm(0.975)*desvio.padrao[2]
[1] 1.941420 2.515715
[1] 0.3514484 0.5039054
```





Regressão de Poisson: estimação pela glm()

estimativas

```
> reg.glm <- glm(y~cov, data=dados10, family=poisson)
> summary(reg.glm)$coeff
```

```
Estimate Std. Error z value Pr(>|z|) (Intercept) 2.2285674 0.14650663 15.21138 2.972301e-52 cov 0.4276769 0.03889281 10.99630 3.981440e-28
```

IC assintótico

```
> confint.default(reg.glm)
```

```
2.5 % 97.5 % (Intercept) 1.9414197 2.5157151 cov 0.3514484 0.5039054
```

IC perfilhado

```
> confint(reg.glm)
```

```
Waiting for profiling to be done...
2.5 % 97.5 %
(Intercept) 1.9327201 2.5074004
cov 0.3525055 0.5050645
```




Regressão contagem-Gama: motivação

- Poisson implica relação média-variância: E(Y) = V(Y);
- Superdispersão (V(Y) > E(Y)): Binomial negativa, Quasi-Poisson, GLMM, . . . ;
- Subdispersão (V(Y) < E(Y)): carente de modelos;
- Experimentos agronômicos: frutos, sementes, brotos, raízes, nós, filhotes, ovos, pústulas, lesões, nódulos, . . .;





Regressão contagem-Gama: introdução



Regressão contagem-Gama: introdução

$$\boxed{ \begin{aligned} \operatorname{Gama}(y;\beta,\alpha) &= \frac{\beta^{\alpha}}{\Gamma(\alpha)} \exp\{-\beta y\} \cdot y^{\alpha-1} \\ \\ \\ \alpha &= 1 \end{aligned}}$$

$$\boxed{ \begin{aligned} \operatorname{Exp}(\beta) &= \beta \exp\{-\beta y\} \end{aligned}}$$





Regressão contagem-Gama: desenvolvimento

• intervalos entre tempo $au \sim \mathsf{Gama}(\alpha, \beta)$,

$$f(\tau, \alpha, \beta) = \frac{\beta^{\alpha}}{\Gamma(\alpha)} \cdot \tau^{\alpha - 1} \cdot \exp\{-\beta \tau\}$$

• tempo até o *n*-ésimo evento $\vartheta_n = \tau_1 + \cdots + \tau_n \sim \mathsf{Gama}(n\alpha, \beta)$,

$$f_n(\vartheta,\alpha,\beta) = \frac{\beta^{n\alpha}}{\Gamma(n\alpha)} \cdot \vartheta^{n\alpha-1} \cdot \exp\{-\beta\vartheta\}$$

• $N_T < n$ se e somente se $\vartheta_n \geq T$,

$$P(N_T < n) = P(\vartheta_n \ge T) = 1 - F_n(T);$$


• $P(N_T = n) = P(N_T < n + 1) - P(N_T < n)$ então

$$P(N_T = n) = F_n(T) - F_{n+1}(T).$$





Regressão contagem-Gama: simulação



Regressão contagem-Gama: verossimilhança

- $F_n(T) = G(T, n\alpha, \beta) = \frac{1}{\Gamma(n\alpha)} \int_0^T u^{n\alpha 1} \cdot \exp\{-\beta u\} du$
- $P(N_T = n) = G(T, n\alpha, \beta) G(T, (n+1)\alpha, \beta)$
- $E(\tau|x) = \frac{\alpha}{\beta} = \exp\{-x^{\top}\gamma\}$
- $\ell(y; x, \alpha, \gamma, T) =$

$$\sum_{i=1}^{n} \ln \left(G(T, y_i \alpha, \alpha \exp\{x_i^{\top} \gamma\}) - G(T, (y_i + 1)\alpha, \alpha \exp\{x_i^{\top} \gamma\}) \right)$$

```
11 <- function(theta, y, X, T=1){</pre>
  eXb <- exp(crossprod(X, theta[-1]))
  sum(log(pgamma(T, theta[1]*v, theta[1]*eXb)-
          pgamma(T, (theta[1]+1)*v, theta[1]*eXb)))
```



Regressão contagem-Gama: estudo de caso


- Número de capulhos do algodão \sim nível de desfolha + estágio fenológico;
- Experimento em vasos, fatorial 5 x 5 com 5 repetições;







Regressão contagem-Gama: análise exploratória







Regressão contagem-Gama: estimação

```
> X <- model.matrix("est:(des+I(des^2)), data=cap)
> rp <- glm(nc~est:(des+I(des^2)), data=cap, family=poisson)</pre>
> cbind(estimativas=coef(rp)) # estimativas
                       estimativas
(Intercept)
                       2.189560352
                    0.436859418
estvegetativo:des
esthotac des
                      0 289715410
estcapulho: I(des^2) -0.019970497
> gam <- coef(rp)
> chutes <- c(alpha=1, gam)
> # estimação por máxima verossimilhança
> op <- optim(chutes, 11, y=cap$nc, X=X, hessian=TRUE,
              method="BFGS", control=list(fnscale=-1))
> cbind(estimativas=op$par)
                                  # estimativas
                        estimativas
alpha
                       5.112297805
(Intercept)
                       2.234239342
estvegetativo:des
                       0.412024360
                     0.274377741
estbotao:des
estcapulho: I(des^2)
                    -0.018586566
> # 2*diferenca da log-verossimilhanca
> dll <- c(diff.ll=2*abs(op$value-c(logLik(rp)))); dll
diff.11
94 83326
```





Regressão contagem-Gama: perfil para α


```
11.alpha <- function(theta, alpha, y, X){
  eXb <- exp(X%*%theta) #*theta[1]
  sum(log(pgamma(1, alpha*y, alpha*eXb)-
          pgamma(1, alpha*y+alpha, alpha*eXb)))
```


```
alpha <- sort(c(seg(3.8.1=30), op$par[1])) # grid de valores para alpha
 perfil <- sapply(alpha,
                   function(a){
                     op <- optim(coef(rp), ll.alpha, alpha=a, y=cap$nc, X=X,
                                 method="BFGS", control=list(fnscale=-1))
                     c(op$value, op$par[1])
> coef <- op$par: vcov <- -solve(op$hessian): llik <- op$value</pre>
> alp <- coef["alpha"]; sd.alp <- sgrt(vcov["alpha","alpha"])</pre>
> dev.perf <- 2*(llik-perfil[1,]) # deviance da log-ver perfilhada
> dev.quad <- (alp-alpha)^2/sd.alp # deviance da apro quadrática
> require(rootSolve)
> qchi <- qchisq(0.95, df=1)
> fperf <- approxfun(alpha, dev.perf-gchi)</p>
> lim <- uniroot.all(fperf, c(0, 10)) # limites do IC perf
> lim2 <- alp+c(-1,1)*1.96*sd.alp # limites do IC assint
```





Regressão contagem-Gama: perfil para α











Regressão contagem-Gama: perfil para α e β_0







Regressão contagem-Gama: resultado final



```
> tabcoef <- data.frame(Estimativas=coef, ErroPadrão=sgrt(diag(vcov)))
> tabcoef$zvalor <- with(tabcoef, Estimativas/ErroPadrão)
```

> tabcoef\$pvalor <- with(tabcoef, pnorm(abs(zvalor), lower=FALSE)*2)</pre>

```
> tabcoef
```

```
Estimativas ErroPadrão
                                                     zvalor
                                                                   pvalor
alpha
                        5.112297805 0.68872753
(Intercept)
                        2.234239342 0.02802741 79.71622031 0.000000e+00
estvegetativo:des
                        0.412024360 0.22796029
                                                 1.80743922 7.069382e-02
estbotao:des
                        0.274377741 0.22448099
                                                 1.22227609 2.216032e-01
estflor:des
                        -1.182180751 0.26654192 -4.43525263 9.196438e-06
estmaca:des
                        0.319589495 0.24988237
                                                1 27895977 2 009112e-01
estcapulho:des
                        0.007104167 0.22267231
                                                 0.03190413 9.745485e-01
estvegetativo:I(des^2) -0.762638914 0.25818749 -2.95381824 3.138688e-03
estbotao: I (des^2)
                        -0.464149443 0.25044536 -1.85329623 6.383991e-02
estflor: I(des^2)
                        0.645341332 0.30030943
                                                 2.14892127 3.164064e-02
estmaca: I(des^2)
                       -1.198887094 0.29689851
                                                -4.03803680 5.390040e-05
estcapulho: I(des^2)
                       -0.018586566 0.24424267 -0.07609877 9.393405e-01
```





Modelo logístico: parametrizações

$$\log(x, \theta, \beta) = \frac{\theta}{1 + f(\exp\{x\}, \beta)}$$
 (1)


- $f_a(x) = \exp\{(a_1 x)/a_2\};$
- $f_b(x) = b_1 \exp\{b_2 x\};$
- $f_c(x) = \exp\{c_1 + c_2 x\};$
- $f_d(x) = (-1 + 1/d_1) \exp\{-d_2x\}.$

$$b_1 = \exp\{a_1/a_2\}$$
 $c_1 = a_1/a_2$ $d_1 = 1/(1 + \exp\{a_1/a_2\})$
 $b_2 = -1/a_2$ $c_2 = -1/a_2$ $d_2 = 1/a_2$.





Modelo logístico: incidência de doença em plantas





Modelo logístico: estimação

```
> 11 <- function(th, y, x, model){
+ ex <- do.call(model, list(x=x, th=th))
+ sd <- sqrt(crossprod(y-ex)/length(x))
+ 11 <- sum(dnorm(y, mean=ex, sd=sd, log=TRUE))
+ 11
+ }
```

```
f.a \leftarrow function(x, th) \{ 1/(1+exp((th[1]-x)/th[2])) \}
> f.b <- function(x, th){ 1/(1+th[1]*exp(th[2]*x)) }
> f.c <- function(x, th){ 1/(1+exp(th[1]+th[2]*x)) }
> f.d <- function(x, th){ 1/(1+(-1+1/th[1])*exp(-th[2]*x)) }
> # dados
> v <- dados$inc2: x <- dados$dia
> # lista com valores iniciais e modelo
> init.list <- list(A=list(par=c(80,13), model=f.a), B=list(par=c(120,-0.06), model=f.b),</pre>
                    C=list(par=c(5,-0.06), model=f.c), D=list(par=c(0.008, 0.065), model=f.d))
> fixed.list <- list(fn=ll, x=x, y=y, method="BFGS", control=list(fnscale=-1))
 # otimização em série dos modelos
> op.all <-
   lapply(init.list,
           function(i){
             op <- do.call(optim, c(i, fixed.list)); op
> # estimativas dos parâmetros e log-verossimilhança
> pars <- sapply(op.all, "[[", "par"); pars
> 110 <- sapply(op.all, "[[", "value"); 110
Γ1. 7 73.12710 120.01001195 4.81592735 0.008455968
[2,] 15.23597 -0.06548208 -0.06584788 0.065166770
57.13773 57.13735 57.13700 57.13430
```

> # parametrizações

Modelo logístico: contornos de confiança

