CE085 - Estatística Inferencial Teoremas Limites

Prof. Wagner Hugo Bonat

Laboratório de Estatística e Geoinformação - LEG Curso de Bacharelado em Estatatística Universidade Federal do Paraná - UFPR

31 de agosto de 2018

Conteúdo



Conteúdo

- 1. Motivação, Definições e Desigualdades.
- 2. Leis dos Grandes Números (LGN)
 - ► LGN de Chebyshev;
 - ► LGN de Kolmogorov;
 - ► LGN de Markov.
- 3. Teorema Central do Limite
 - ► Teorema de Lindeberg-Levy;
 - ► Teorema de Lindeberg-Levy multivariado;
 - ► Teorema de Lindeberg-Feller;
 - Teorema de Liapounov;
 - Teorema de Slutsky.



Motivação, Definições e Desigualdades



- ▶ Sejam $Y_1, Y_2, ..., Y_n$ variáveis aleatórias (v.a) independentes e idênticamente distribuídas (iid) com $E(Y_i) = \mu$ e $V(Y_i) = \sigma^2$.
- Objetivo: Baseado em um conjunto de realizações de Y_i estimar o valor μ.
- ightharpoonup Estratégia simples: Usar a versão empírica de μ , i.e.

$$\hat{\mu} = \sum_{i=1}^{n} \frac{Y_i}{n}.$$

 $ightharpoonup \hat{\mu}$ é uma variável aleatória?



- ▶ Sejam $Y_1, Y_2, ..., Y_n$ variáveis aleatórias (v.a) independentes e idênticamente distribuídas (iid) com $E(Y_i) = \mu$ e $V(Y_i) = \sigma^2$.
- ▶ Objetivo: Baseado em um conjunto de realizações de Y_i estimar o valor μ .
- ightharpoonup Estratégia simples: Usar a versão empírica de μ , i.e.

$$\hat{\mu} = \sum_{i=1}^{n} \frac{Y_i}{n}.$$

- $\hat{\mu}$ é uma variável aleatória?
- Qual a esperança de $\hat{\mu}$?



- ▶ Sejam $Y_1, Y_2, ..., Y_n$ variáveis aleatórias (v.a) independentes e idênticamente distribuídas (iid) com $E(Y_i) = \mu$ e $V(Y_i) = \sigma^2$.
- ▶ Objetivo: Baseado em um conjunto de realizações de Y_i estimar o valor μ .
- ightharpoonup Estratégia simples: Usar a versão empírica de μ , i.e.

$$\hat{\mu} = \sum_{i=1}^{n} \frac{Y_i}{n}.$$

- $ightharpoonup \hat{\mu}$ é uma variável aleatória?
- Qual a esperança de $\hat{\mu}$?
- ▶ Qual a variância de $\hat{\mu}$?



- ▶ Sejam $Y_1, Y_2, ..., Y_n$ variáveis aleatórias (v.a) independentes e idênticamente distribuídas (iid) com $E(Y_i) = \mu$ e $V(Y_i) = \sigma^2$.
- Objetivo: Baseado em um conjunto de realizações de Y_i estimar o valor μ.
- ► Estratégia simples: Usar a versão empírica de μ , i.e.

$$\hat{\mu} = \sum_{i=1}^{n} \frac{Y_i}{n}.$$

- $ightharpoonup \hat{\mu}$ é uma variável aleatória?
- Qual a esperança de $\hat{\mu}$?
- Qual a variância de $\hat{\mu}$?
- ▶ Qual é a distribuição de probabilidade de $\hat{\mu}$?



Sequência de v.a

▶ Definição 1 (Sequência de v.a's): Sejam $X_1, X_2, ..., X_n$ v.a's (v.a) com função de probabilidade (fp) ou função densidade de probabilidade (fdp) $f(X, \theta)$. Para uma função $g(\cdot)$ define-se uma sequência de v.a's como,

$$Y_1 = g(X_1)$$

 $Y_2 = g(X_1, X_2)$
 \vdots
 $Y_n = g(X_1, ..., X_n).$

- Estatísticas amostrais são funções do tamanho da amostra e podem ser tratadas como sequência de v.a's.
- Exemplos: Média e variância amostral.

Convergência em probabilidade

- Definição 2 (Convergência em probabilidade):
- ▶ Seja $Y_1, ..., Y_n$ uma sequência de v.a's. Dizemos que Y_n converge em probabilidade para uma constante ou v.a Y, se $\forall \epsilon > 0$, tem-se

$$\lim_{n\to\infty} P(|Y_n - Y| > \epsilon) = 0.$$

- ► Notação: $Y_n \stackrel{P}{\rightarrow} Y$.
- Observações:
 - 1. $Y_n \stackrel{P}{\to} Y$ é equivalente a $(Y_n Y) \stackrel{P}{\to} 0$.
 - 2. Para vetores aleatórios, tem-se

$$\mathbf{Y}_n = (Y_{n1}, \dots, Y_{nk})^{\top}, \mathbf{Y}_n \stackrel{p}{ o} \mathbf{Y}$$
 se $Y_{ni} \stackrel{p}{ o} \mathbf{Y}_i$ para $i = 1, \dots, n$.



Desigualdades

► Markov: Seja Y uma v.a não negativa com $E(Y) = \mu$ e $\epsilon > 0$. Então,

$$P(Y \ge \epsilon) \le \frac{E(Y)}{\epsilon}.$$

- Demonstração.
- ► Chebyshev: Seja Y qualquer v.a com $E(Y) = \mu$ e $Var(Y) = \sigma^2$ ambos finitos. Então, para todo $\epsilon > 0$

$$P(|Y - \mu| > \epsilon) \le \frac{Var(Y)}{\epsilon^2} = \frac{\sigma^2}{\epsilon^2}.$$

- Demonstração.
- lacktriangle Corolário: Seja $\psi(\cdot)$ uma função monotônica, então

$$P(\psi(|Y|) > \psi(\epsilon)) \le \frac{E(\psi(Y))}{\psi(\epsilon)}.$$



Leis dos Grandes Números



Lei dos Grandes Números: Chebyshev

► Teorema 1: Seja Y_1, \ldots, Y_n v.a. iid com $E(Y_i) = \mu$ e $Var(Y_i) = \sigma^2$ ambos finitos. Então,

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^{n} Y_i \stackrel{P}{\rightarrow} E(Y_i) = \mu.$$

- ► Demonstração.
- Ilustração computacional.



Lei dos Grandes Números: Kolmogorov

► Teorema 2: Seja Y_1, \ldots, Y_n v.a. iid com $E(|Y_i|) < \infty$ e $E(Y_i) = \mu$. Então,

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^{n} Y_i \stackrel{P}{\rightarrow} E(Y_i) = \mu.$$

- ► Condição $E(|Y_i|) < \infty$ significa que $E(|Y_i|) = \int |y_i| f(y_i, \theta) dy_i < \infty$. Controla as caudas da distribuição.
- ► Caudas não podem ser muito pesadas, tal que $E(|Y_i|) = \infty$, mas ainda podem ser pesadas a ponto de $E(Y_i^2) = \infty$.
- ► Kolmogorov não requer que Var(Y_i) exista.
- Kolmororov cobre distribuições com caudas pesadas como a t-Student.
- ▶ Demonstração é trabalhosa em sua forma geral.
- ► Ilustração computacional.

Lei dos Grandes Números: Markov

► Teorema 3: Seja Y_1, \ldots, Y_n uma amostra não correlacionada com médias finitas $E(Y_i) = \mu_i$ e variâncias uniformemente limitadas $Var(Y_i) = \sigma_i^2 \leq M < \infty$ para $i = 1, \ldots, n$. Então,

$$\bar{Y}-\bar{\mu}=\frac{1}{n}\sum_{i=1}^nY_i-\frac{1}{n}\sum_{i=1}^n\mu_i=\frac{1}{n}\sum_{i=1}^n(Y_i-\mu_i)\overset{P}{\to}0.$$

- ► LGN de Markov não requer amostras iid.
- Relaxar iid observações requer uma restrição mais forte na variância da v.a.
- ▶ Demonstração.
- ► Ilustração computacional.



Manipulação de limites e convergência em probabilidade

► Teorema 4: Teorema de Slutsky

Sejam Y_n e Z_n sequências de v.a's e sejam b, c e d constantes.

- a) Se $Y_n \stackrel{P}{\rightarrow} c$ então $bY_n \stackrel{P}{\rightarrow} bc$.
- b) Se $Y_n \stackrel{P}{\to} c e Z_n \stackrel{P}{\to} d$ então $Y_n + Z_n \stackrel{P}{\to} c + d$.
- c) Se $Y_n \stackrel{P}{\to} c$ e $Z_n \stackrel{P}{\to} d$ então $\frac{Y_n}{Z_n} \stackrel{P}{\to} \frac{c}{d}$ desde que $d \neq 0$ e $Y_n Z_n \stackrel{P}{\to} cd$.
- d) Se $Y_n \stackrel{P}{\to} c$ e $h(\cdot)$ é uma função contínua então $h(Y_n) \stackrel{P}{\to} h(c)$.



Teorema do Limite Central



Convergência em distribuição

► Seja $Y_1, ..., Y_n$ uma sequência de v.a. Dizemos que Y_n converge em distribuição para uma v.a Y e escrevemos $Y_n \stackrel{D}{\rightarrow} Y$ se

$$F_{Y_n}(y) = P(Y_n \leq y) \to F_Y(y) = P(Y \leq y), \quad n \to \infty.$$

- ► Na maioria das aplicações Y será normal ou qui-quadrado.
- Convergência em distribuição em geral é demonstrada via Teorema Central do Limite.
- Se n é grande usamos a distribuição de Y como uma aproximação para a distribuição de Y_n .
- ▶ Distribuição exata de Y_n em geral é dificil de se obter.



Função geradora de momentos

A função geradora de momentos da v.a Y é $M_Y(t) = E(e^{tY})$, ou seja

$$M_{Y}(t) = \int_{-\infty}^{\infty} e^{ty} f(y) dy.$$

▶ Diferenciando $M_Y(t)$, temos

$$\begin{aligned} M_{Y}^{(r)}(t) &= \frac{d^{r}}{dt^{r}} \int_{-\infty}^{\infty} e^{ty} f(y) dy \\ &= \int_{-\infty}^{\infty} \left(\frac{d^{r}}{dt^{r}} e^{ty} f(y) \right) dy = \int_{-\infty}^{\infty} y^{r} e^{ty} f(y) dy. \end{aligned}$$

Fazendo t = 0, temos

$$\int_{-\infty}^{\infty} y^r e^{ty} f(y) dy = E(Y^r).$$



Função geradora de momentos

- ▶ Proposição 1: Se X e Y são v.a independentes com fgm $M_X(t)$ e $M_Y(t)$. Seja Z = X + Y, então $M_Z(t) = M_X(t)M_Y(t)$.
- ▶ Proposição 2: Se X é uma v.a com fgm $M_X(t)$ e Y = a + bX, então $M_Y(t) = e^{at}M_X(bt)$.
- ► Teorema da Continuidade de Levy: Seja F_n uma sequência de funções de distribuições acumuladas com correspondentes funções geradoras de momentos $M_n(t)$. Seja F uma cdf com fgm M(t). Se $M_n(t) \rightarrow M(t) \quad \forall t$ em um intervalo aberto contendo zero, então $F_n(y) \rightarrow F_Y(y) \quad \forall y$.
- Função geradora de momentos distribuição normal padrão $e^{t^2/2}$.

Teorema Central do Limite

► Teorema Lindeberg-Levy: Seja Y_1, \ldots, Y_n uma amostra iid com $E(Y_i) = \mu$ e $V(Y_i) = \sigma^2 < \infty$. Então,

$$\sqrt{n}\left(\frac{\bar{Y}-\mu}{\sigma}\right) \overset{D}{\to} Z \sim \textit{N}(0,1), \quad \text{para} \quad n \to \infty.$$

▶ Isso significa que, para todo $y \in \Re$,

$$P(Y_n \le y) \to \Phi(y)$$
 quando $n \to \infty$,

onde

$$\Phi(y) = \int_{-\infty}^{y} \phi(z) dz \quad e \quad \phi(z) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}z^2\right).$$

► Forma alternativa: $\bar{Y} \sim N(\mu, \sigma^2/n)$.



Teorema Central do Limite (versão multivariada)

► Teorema Lindeberg-Levy multivariado: Sejam Y_1, \ldots, Y_n vetores aleatórios p-dimensionais com $E(Y_i) = \mu$ e $V(Y_i) = [(Y_i - \mu)(Y_i - \mu)^\top] = \Sigma$, onde Σ é não-singular. Denote $\Sigma^{-1} = \Sigma^{-\frac{1}{2}} \Sigma^{-\frac{1}{2}}$. Então,

$$\sqrt{n} \Sigma^{-\frac{1}{2}} (\bar{\boldsymbol{Y}} - \boldsymbol{\mu}) \overset{D}{\rightarrow} \boldsymbol{Z} \sim N(\boldsymbol{0}, \boldsymbol{I}),$$

onde $N(\mathbf{0}, \mathbf{I})$ denota uma distribuição normal multivariada com média zero e matriz de covariância identidade,

$$f(\mathbf{z}) = (2\pi)^{-p/2} \exp\left(-\frac{1}{2}\mathbf{z}^{\top}\mathbf{z}\right).$$

Formas alternativas

$$\sqrt{n}(\mathbf{ar{Y}}-\mathbf{\mu})\sim N(\mathbf{0},\mathbf{\Sigma})$$
 $\mathbf{ar{Y}}\sim N(\mathbf{\mu},n^{-1}\mathbf{\Sigma}).$



Teorema Central do Limite

► Teorema Lindeberg-Feller: Seja Y_1, \ldots, Y_n v.a independentes $E(Y_i) = \mu_i$ e $V(Y_i) = \sigma_i^2 < \infty$. Defina, $\bar{\mu}_n = n^{-1} \sum_{i=1}^n \mu_i$ e $\bar{\sigma}_n^2 = n^{-1} \sum_{i=1}^n \sigma_i^2$. Suponha que

$$\lim_{n\to\infty} \max_{i} \frac{\sigma_{i}^{2}}{n\bar{\sigma}_{n}^{2}} = 0$$

$$\lim_{n\to\infty} \bar{\sigma}_{n}^{2} = \bar{\sigma}^{2} < \infty.$$

Então

$$\sqrt{n}\left(\frac{\bar{Y}-\bar{\mu}_n}{\bar{\sigma}_n^2}\right) \overset{D}{\to} Z \sim N(0,1).$$

▶ De forma equivalente,

$$\sqrt{n}(\bar{Y}-\bar{\mu}_n)\stackrel{D}{\rightarrow} N(0,\bar{\sigma}_n^2).$$



Teorema Central do Limite

► Teorema Liapounov: Sejam $Y_1, ..., Y_n$ v.a independentes $E(Y_i) = \mu_i$ e $V(Y_i) = \sigma_i^2 < \infty$. Suponha que

$$E[|Y_i - \mu_i|^{2+\delta}] \le M < \infty$$

para algum $\delta > 0$. Se $\bar{\sigma}_n^2$ é positiva e finita para todo n suficientemente grande, então

$$\sqrt{n} \left(\frac{\bar{Y} - \bar{\mu}_n}{\bar{\sigma}_n} \right) \overset{D}{\to} Z \sim N(0,1).$$

► Equivalentemente,

$$\sqrt{n}(\bar{Y} - \bar{\mu}_n) \stackrel{D}{\rightarrow} N(0, \bar{\sigma}^2).$$

Liapounov é equivalente a Lindeberg-Feller só que mais simples de entender e verificar na prática.



Resultados para manipular TCL's

- ► Teorema Slutsky: Sejam Y_n e Z_n sequência de v.a tais que $Y_n \stackrel{D}{\to} Y$ e $Z_n \stackrel{P}{\to} c$, onde Y é uma v.a e c é uma constante. Então, os seguintes resultados valem quando $n \to \infty$:
 - 1. $Z_n Y_n \stackrel{D}{\rightarrow} cY$.
 - 2. $\frac{Y_n}{Z_n} \stackrel{D}{\to} \frac{Y}{c}$ desde que $c \neq 0$.
 - 3. $Y_n + Z_n \stackrel{D}{\rightarrow} Y + c$.
- Exercício: Seja Y_1, \ldots, Y_n v.a iid com $E(Y_i) = \mu$ e $V(Y_i) = \sigma^2 < \infty$.
 - a) Mostre que $\bar{\sigma}^2 \stackrel{P}{\to} \sigma^2$ onde $\bar{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (Y_i \mu)^2$.
 - b) Obtenha a distribuição aproximada de $\bar{\sigma}^2$.

